Estrategia óptima de modelado predictivo del rendimiento de cebada maltera para AgroCebada 2026

Síntesis ejecutiva y diagnóstico del problema

El reto, tal como está planteado, **no es principalmente un problema de elegir "el mejor algoritmo"**. Es un problema de construir una representación agronómica compacta y correcta a partir de decenas de miles de observaciones temporales, evitando tres riesgos que dominan con $N = 138$: **sobreajuste por alta dimensionalidad, fuga espacial y confusión entre región y rendimiento**. Con 138 parcelas de entrenamiento, cualquier pipeline que entregue centenares de variables directamente a XGBoost, LightGBM o Random Forest probablemente producirá una validación aparente excelente y una generalización mucho más débil.

La señal regional del conjunto de entrenamiento es extraordinariamente fuerte: Puebla/Chignahuapan promedia 4.48 t/ha, Hidalgo 3.76 t/ha y Tlaxcala 2.98 t/ha. Esto significa que `ESTADO`, coordenadas, municipio, suelo, precipitación, elevación y hasta ciertos patrones satelitales pueden actuar como **proxies mutuamente correlacionados de una "identidad regional"**. Esa estructura puede ser real —clima, suelo, manejo, germoplasma—, pero también puede inducir un modelo a memorizar regiones. La literatura de validación espacial demuestra que ignorar esta dependencia conduce a una subestimación sistemática del error predictivo. [1]

La arquitectura que recomiendo para AgroCebada es, por tanto:

Componente	Recomendación
Unidad de modelado	Una fila por parcela
Series satelitales	Convertirlas a **fenometrics y métricas de estrés**, no usar observaciones fecha×índice crudas
Fenología	Alinear por **fases fenológicas/GDD**, no solamente por mes calendario
Sentinel-2	Rama propia a 10 m
Landsat	Rama propia o HLS como rama secundaria
Planet	**Rama independiente**, sin mezclar valores crudos con S2/Landsat
Clima	Variables diarias agregadas por fenofase: GDD, lluvia, VPD, radiación, ET_0, extremos térmicos
Suelo	SoilGrids/OpenLandMap + INEGI; priorizar AWC, textura, SOC, pH y densidad
Dimensionalidad	Aproximadamente 20–40 variables fuertes por modelo, no

Componente	Recomendación
final	cientos
Selección	Filtro agronómico → redundancia → mRMR/ElasticNet-estabilidad; Boruta-SHAP sólo como análisis complementario
Validación primaria	Spatial/Group K-fold de 5 bloques geográficos
Validación extrema	Leave-one-state-out Puebla/Hidalgo/Tlaxcala
Modelos prioritarios	ElasticNet/Bayesian Ridge + SVR + CatBoost/XGBoost regularizados
GPR	Muy interesante si se reduce previamente a $\lesssim 15$ variables
Ensemble	Convex blend de 2–3 modelos basado **exclusivamente en predicciones out-of-fold espaciales**
XAI	SHAP fold-wise + pruebas de congruencia fisiológica
Métricas	RMSE y MAE primarias; R^2 y MAPE secundarias

Hay además una oportunidad que considero especialmente importante: **conectar las variables directamente con la identidad fisiológica del rendimiento**. En primera aproximación,

$$Y\ [\mathrm{t/ha}] \approx \frac{S\ [\mathrm{espigas/m^2}] \times G\ [\mathrm{granos/espiga}] \times PMG\ [\mathrm{g/1000\ granos}]}{100\,000}$$

Por ejemplo, 500 espigas/m^2 × 20 granos/espiga × 40 g de PMG ≈ 4.0 t/ha. El objetivo de la ingeniería de variables debería ser reconstruir indirectamente esos tres componentes: **capacidad de macollamiento/supervivencia de tallos, establecimiento reproductivo y capacidad de llenado del grano**. La literatura sobre cebada confirma que sequía y temperatura pueden modificar simultáneamente número de tallos/espigas, fertilidad y peso final del grano. [2]

Un resultado metodológico importante es que los datos de Planet 2025 probablemente sean su **mejor sensor para reconstruir fenología**, especialmente en las parcelas pequeñas, mientras que Sentinel-2 aporta una excelente combinación entre resolución espacial, red-edge y series multianuales; Landsat tiene mucho menor número de píxeles puros en las parcelas más pequeñas. Una parcela de 0.35 ha contiene teóricamente sólo unas cuatro celdas Landsat de 30 m antes de descontar bordes, frente a unas 35 celdas Sentinel-2 de 10 m y cientos de píxeles Planet de aproximadamente 3 m. Por ello, la confiabilidad de una observación debe depender también del **número efectivo de píxeles válidos y de la fracción de borde**, no sólo de `porcentaje_nubosidad`.

La estrategia final que considero con mayor probabilidad de generalizar es un **ensamble pequeño entre un modelo lineal regularizado, un boosting fuertemente**

regularizado y SVR/GPR, alimentado con 20–40 variables de alta calidad. Un ensamble de baja complejidad suele ser preferible aquí a un stacking profundo porque sólo existen 138 etiquetas; la complejidad debe invertirse en la representación agronómica, no en el meta-modelo.

Fenología, formación del rendimiento y ventanas críticas

La escala Zadoks proporciona una forma mucho más robusta de organizar la cebada que los meses del calendario. En un ciclo Primavera–Verano de abril–octubre en el altiplano mexicano, las fechas absolutas variarán por fecha de siembra, cultivar, humedad y temperatura; por ello no aconsejo codificar, por ejemplo, "julio = encañado" de forma rígida. El modelo debe inferir o aproximar las etapas individualmente mediante GDD y las curvas Planet/Sentinel-2. Los modelos de cultivo como CERES-Barley simulan precisamente el desarrollo mediante acumulación térmica y estados fenológicos, no simplemente mediante fecha juliana. [3]

Fase	Zadoks aproximado	Proceso fisiológico dominante	Variables que conviene modelar
Siembra–emergencia	Z00–Z19	Germinación, establecimiento	humedad inicial, precipitación, GDD, NDVI basal
Macollamiento	Z20–Z29	Formación de tallos	LAI/NDVI ascendente, tasa de crecimiento, lluvia/AWC
Encañado	Z30–Z39	Elongación, crecimiento rápido, desarrollo de espiga	pendiente NDVI/LAI, radiación, VPD, agua
Embuche–espigado	Z40–Z59	Meiosis, supervivencia floral, emergencia de espiga	Tmax, Tmin, VPD, AWC, NDVI/LAI máximo
Antesis	Z60–Z69	Polinización/fertilización	calor, helada, déficit hídrico
Llenado	Z70–Z89	Acumulación de almidón y peso de grano	radiación, temperatura, agua, senescencia
Madurez	Z90+	Pérdida de humedad / cosecha	velocidad de senescencia, EOS

En cebada, la antesis está muy próxima al espigado y puede iniciarse incluso antes de que la espiga haya emergido completamente, característica que hace particularmente vulnerable el período de embuche–espigado. Experimentalmente se

ha observado que temperaturas elevadas desde iniciación de espiga hasta antesis reducen número de espiguillas y granos, mientras que calor durante llenado reduce peso y calidad del grano. [4]

Número de espigas por metro cuadrado. Se origina en el macollamiento, pero el número final de espigas productivas depende tanto de cuántos macollos se forman como de cuántos sobreviven hasta encañado/embuche. Por ello, una señal vigorosa de NDVI/LAI durante macollamiento que posteriormente colapsa no equivale necesariamente a un alto número final de espigas. La sequía durante crecimiento temprano y elongación puede reducir macollos, biomasa y posteriormente espigas. [5]

Número de granos por espiga. El potencial empieza a determinarse desde iniciación de la espiga y desarrollo de espiguillas, pero el componente que interesa al rendimiento queda definido esencialmente durante el período crítico preantesis–antesis por supervivencia de floretes, meiosis y fertilización. En cebada se ha documentado sensibilidad térmica desde semanas antes del espigado; temperaturas superiores a aproximadamente 20 °C durante desarrollo reproductivo aceleran la fenología y pueden reducir espiguillas/granos. [6]

Peso de mil granos. Aunque el potencial de tamaño de grano tiene determinantes preantesis, el PMG realizado se construye predominantemente después de la fecundación, durante llenado. La combinación peligrosa es **alta temperatura + alto VPD + agotamiento de agua del suelo**, porque acelera senescencia y acorta el período efectivo de llenado. Experimentos de cebada muestran que temperaturas sostenidas superiores a 30 °C durante floración/desarrollo de grano constituyen estrés crónico, mientras que exposiciones por encima de 35 °C se consideran eventos agudos de calor. [7]

Temperatura térmica efectiva

Aquí es importante evitar una falsa precisión. **No existe una única tripleta universal $T_b/T_{opt}/T_{max}$ válida para todas las variedades y todas las fases de cebada**. En CERES-Barley se utiliza $T_b \approx 0\,^{\circ}C$ y la tasa de desarrollo aumenta hasta un óptimo cercano a $26\,^{\circ}C$; por encima del óptimo, la formulación del desarrollo fenológico puede mantener la tasa máxima en lugar de imponer inmediatamente una reducción. En otras palabras, la “temperatura máxima cardinal” depende del modelo y no debe confundirse con la temperatura de daño térmico. [8]

Para AgroCebada recomiendo comenzar con:

$$T_b = 0\,^{\circ}C$$

y un GDD diario simple:

$$GDD_d = \max\left[0, \frac{T^*_{\max,d} + T^*_{\min,d}}{2} - T_b\right]$$

donde

$$T^*_{\max,d} = \min(T_{\max,d}, 26)$$

$$T^*_{\min,d} = \max(T_{\min,d}, 0).$$

Así se impide que un día extremadamente caliente aporte "desarrollo beneficioso" ilimitado. El calor por encima de 26–30 °C debe entrar **por variables de estrés independientes**, no como GDD extra. CERES-Barley y estudios de respuesta térmica apoyan el uso de $0\,^{\circ}C$ como base y un óptimo cercano a 26 °C. [9]

Por tanto, mi recomendación práctica para el reto no es imponer una dudosa tripleta 0/26/35 como si fuese una constante fisiológica. Sería:

$$\boxed{T_b = 0^{\circ}C, \qquad T_{opt} \simeq 26^{\circ}C}$$

con **26 °C como techo de acumulación de GDD**, y variables separadas:

$$N_{30} = \sum I(T_{\max} > 30^{\circ}C)$$

$$N_{32} = \sum I(T_{\max} > 32^{\circ}C)$$

$$N_{35} = \sum I(T_{\max} > 35^{\circ}C)$$

calculadas dentro de `booting_anthesis` y `grain_fill`. La evidencia experimental distingue estrés crónico alrededor de $> 30^{\circ}C$ y daño agudo alrededor de $> 35^{\circ}C$ durante floración/llenado. [10]

Estrés hídrico

No aconsejo establecer un umbral de "X milímetros de lluvia" porque el mismo evento tiene efectos distintos según textura, profundidad radical, ET atmosférica y humedad precedente. Una formulación físicamente mejor es el balance de agua disponible de FAO-56:

$$TAW = 1000(\theta_{FC} - \theta_{WP})Z_r$$

donde TAW es agua total disponible en mm, Z_r profundidad de raíces en metros, θ_{FC} humedad a capacidad de campo y θ_{WP} humedad al punto de marchitez.

El agua fácilmente aprovechable es

$$RAW = p\,TAW$$

y cuando el agotamiento D_r excede RAW, puede emplearse:

$$K_s = \frac{TAW - D_r}{TAW - RAW}, \qquad 0 \le K_s \le 1.$$

Para el modelo, más que intentar reconstruir un balance perfectamente mecanístico, conviene obtener indicadores como `water_deficit_boot`, `water_deficit_anthesis`,

`water_deficit_fill`, número de días $K_s < 0.8$ y déficit acumulado $ET_0 - P$. La cebada puede tolerar déficit vegetativo moderado, pero sequía alrededor de elongación, espigado/antesis e inicio del desarrollo del grano afecta simultáneamente espigas, granos y peso individual. [11]

Heladas y calor

La mayor susceptibilidad a helada ocurre desde embuche hasta floración. Fuentes agronómicas de extensión reportan daño reproductivo en cebada alrededor de $28\,^{\circ}F$, aproximadamente $-2.2\,^{\circ}C$, especialmente porque la cebada puede florecer mientras la espiga aún está parcialmente protegida por la vaina. [12]

Para los Valles Altos construiría, por fenofase:

$$F_0 = \sum I(T_{\min} < 0)$$

$$F_{-2} = \sum I(T_{\min} < -2)$$

$$F_{-4} = \sum I(T_{\min} < -4).$$

No deben interpretarse como fronteras absolutas: temperatura del dosel, duración del evento, viento, humedad y topografía cambian mucho el daño real. Las parcelas bajas o depresiones pueden presentar temperaturas de dosel inferiores a la estación meteorológica.

El riesgo agronómico esperado puede resumirse así:

Ventana	Amenaza	Componente afectado
Emergencia–macollamiento	sequía	establecimiento y macollos
Encañado	sequía / calor	biomasa y supervivencia de tallos
Embuche–antesis	**helada, calor, VPD alto**	fertilidad y granos/espiga
Antesis–grano lechoso	sequía + calor	número final y comienzo de llenado
Grano lechoso–pastoso	calor / déficit hídrico	PMG
Madurez	lluvia excesiva	secado, acame, enfermedad/calidad

La ventaja de organizar las variables de esta forma es que SHAP podrá posteriormente responder preguntas fisiológicas: “¿el modelo penaliza realmente tres días >32 °C durante llenado?” en lugar de la mucho menos interpretable “¿julio Tmax tuvo importancia?”.

Disparidad regional, agroecología y señal climática de 2025

La diferencia Puebla–Hidalgo–Tlaxcala debe tratarse como una **hipótesis causal por descomponer**, no como una etiqueta que el modelo deba aprender ciegamente. Los Llanos de Apan constituyen una región histórica de producción de cebada maltera y el cultivo tiene gran importancia económica en Hidalgo; documentación gubernamental mexicana identifica a Apan como una zona central de esta cadena productiva. [13]

A partir de los datos del reto, la diferencia entre Chignahuapan y Calpulalpan es de aproximadamente **1.50 t/ha**, casi 50 % del rendimiento medio de Tlaxcala. Es demasiado grande para asumir de entrada que proviene de una sola variable climática. En términos conceptuales,

$$Y = f(\text{agua,radiación,temperatura,suelo,cultivar,fecha de siembra,fertilidad,sanidad,manejo}) + \epsilon.$$

La producción mexicana de cebada también está expuesta a enfermedades como royas, de modo que una temporada húmeda puede simultáneamente favorecer crecimiento vegetativo y aumentar presión de enfermedad; por eso “más lluvia = más rendimiento” no debe imponerse como una relación monotónica. [14]

Chignahuapan. Bajo el contexto geográfico descrito para el reto —zona elevada asociada a Sierra Norte y mayor influencia orográfica— la hipótesis principal es un sistema con **menor probabilidad de déficit hídrico terminal**, mayor persistencia de área foliar y potencialmente mayor disponibilidad de agua durante encañado–llenado. Si los suelos además presentan mayor almacenamiento efectivo, el cultivo puede mantener LAI y fotosíntesis durante el período crítico. Pero la misma humedad puede elevar nubosidad, reducir radiación efectiva o favorecer enfermedades; esas relaciones deben verificarse, no asumirse.

Apan/Singuilucan y el corredor de Hidalgo. Es esperable mayor exposición de los cultivos a la combinación de viento, demanda atmosférica y variabilidad de lluvias característica de una planicie alta. Agronómicamente, un ambiente así puede sostener rendimientos altos cuando lluvia y fertilidad coinciden con las ventanas críticas, pero castigar con rapidez la supervivencia de macollos y el llenado bajo déficit hídrico. La gran dispersión de Hidalgo en el conjunto de entrenamiento —0.78 t/ha— es consistente con una población ambiental y de manejo más heterogénea que Chignahuapan o Tlaxcala, aunque esa interpretación debe validarse con los covariables.

Calpulalpan/Nanacamilpa. Su promedio de 2.98 t/ha y desviación de sólo 0.38 t/ha sugiere algo más que “mal clima”: podría existir un techo relativamente uniforme asociado a manejo, germoplasma, disponibilidad de N, suelo, fecha de siembra o incluso al procedimiento con el que se reportó el rendimiento. Antes de modelar,

conviene comprobar el número de valores únicos y el redondeo de `RENDIMIENTO_T_HA`; un grado de cuantización distinto entre estados puede aparecer engañosamente como una señal biológica.

Un diagnóstico muy revelador será comparar, por estado, las curvas promedio de 2025:

$$NDVI(t), \quad LAI(t), \quad NDWI(t)$$

y particularmente separar cuatro mecanismos:

vigor máximo, duración verde, agua durante reproducción, velocidad de senescencia.

Si Puebla no sólo tiene NDVI máximo superior, sino además mayor AUC posespigado y senescencia más lenta, existiría evidencia remota de una ventaja en **duración fotosintética durante llenado**. Si el pico es similar pero Tlaxcala cae antes, la explicación cambiaría hacia estrés terminal. Los estudios de fenología satelital de cereales muestran que incorporar fechas, amplitudes e integrales de la curva mejora la relación con rendimiento frente al uso de una única imagen. [15]

Qué puede afirmarse sobre 2025

Sería metodológicamente incorrecto declarar, sin procesar sus rasters o una serie meteorológica local, que "Calpulalpan sufrió X % de sequía" o "Chignahuapan recibió Y mm más que lo normal". El hecho de que 2025 ocurriera en un contexto global excepcionalmente cálido —la OMM posteriormente confirmó 2025 entre los años más cálidos observados— **no demuestra por sí solo una anomalía con el mismo signo en cada municipio del altiplano**. [16]

Sus propios datos permiten responderlo de forma mucho más rigurosa, pero hay que extender el período climatológico. **2022–2024 no constituye una climatología suficiente.** Recomiendo descargar CHIRPS/CHIRTS o ERA5-Land para 1991–2020 y calcular, para cada celda/parcela:

$$P'_{m,2025} = 100\,\frac{P_{m,2025} - \overline{P}_{m,1991:2020}}{\overline{P}_{m,1991:2020}}$$

y

$$T'_{m,2025} = T_{m,2025} - \overline{T}_{m,1991:2020}.$$

Para precipitación, es mejor todavía trabajar diariamente y calcular:

$$CDD = \max(\text{número consecutivo de días con } P < 1\,mm)$$

$$Rx5day = \max(\text{precipitación acumulada en 5 días})$$

además de lluvia acumulada por fenofase. Así se distingue una temporada con precipitación total "normal" pero distribuida en pocos aguaceros de otra con lluvias agronómicamente útiles y regulares.

El diagnóstico que recomiendo ejecutar antes de entrenar el modelo es:

Región	Variables a comparar 2025 vs. climatología
Chignahuapan	lluvia acumulada encañado–llenado, CDD, radiación, VPD, Tmax >30
Apan/Singuilucan	CDD, VPD, $ET_0 - P$, heladas tempranas/tardías, lluvia preantesis
Calpulalpan	déficit hídrico reproductivo, CDD, Tmin extremas, senescencia Planet
Todas	GDD, fecha de pico NDVI, AUC pospico, Tmax >30/35, Tmin <0/−2

Finalmente, la explicación regional debe comprobarse mediante una **descomposición estadística**. Entrenaría sucesivamente modelos con: sólo región; región+topografía; +suelo; +clima; +satélite. Si el RMSE cae fuertemente al incorporar AWC y estrés hídrico y simultáneamente disminuye la importancia SHAP de `ESTADO`, entonces se habrá reemplazado un proxy administrativo por mecanismos agroecológicos reales.

Datos externos públicos e integración geoespacial

Suelo y edafología

SoilGrids es probablemente la incorporación externa con mayor relación beneficio/costo. ISRIC ofrece predicciones globales de propiedades del suelo a aproximadamente 250 m y seis profundidades estándar: 0–5, 5–15, 15–30, 30–60, 60–100 y 100–200 cm. Incluye arcilla, arena, limo, SOC, pH, densidad aparente, CEC, N y variables de contenido de agua, además de cuantiles de incertidumbre. [17]

Fuente	Resolución	Variables recomendadas	Acceso
SoilGrids/ISRIC	250 m; 6 profundidades	clay, sand, silt, SOC, pH, bulk density, CEC, water content	WCS, WebDAV, GEE
OpenLandMap	típicamente 250 m	textura, SOC, pH, bulk density, agua a tensiones especificadas	Google Earth Engine
INEGI Edafología Serie II	1:250 000	grupo/unidad de suelo, textura y fases edáficas	vectorial nacional
CHIRPS	0.05°	precipitación	GeoTIFF/NetCDF

Fuente	Resolución	Variables recomendadas	Acceso
		diaria/mensual histórica	
NASA POWER	rejilla global, dependiente del parámetro	radiación, T, RH/dew point, viento, P	REST JSON/CSV/NetCDF
ERA5-Land	0.1° distribuido; ~9 km nativo	T, Td, lluvia, radiación, viento, suelo, ET	CDS API, GRIB/NetCDF
SMN/CONAGUA	estaciones	T, RH, radiación, viento, presión, lluvia	lista/KMZ/red de estaciones
SIAP	municipio/año	superficie, producción, rendimiento, modalidad	portal de cierre agrícola

SoilGrids publica servicios WMS/WCS en `https://maps.isric.org` y descargas en `https://files.isric.org/soilgrids/latest/data/`; ISRIC mantiene además documentación y ejemplos para Google Earth Engine. [18]

Una consulta WCS puede construirse conceptualmente como:

```
https://maps.isric.org/mapserv?
map=/map/clay.map&
SERVICE=WCS&
VERSION=2.0.1&
REQUEST=GetCoverage&
COVERAGEID=clay_0-5cm_mean&
FORMAT=image/tiff&
SUBSET=long(-98.613,-98.1967)&
SUBSET=lat(19.5238,19.9844)
```

Conviene comprobar `DescribeCoverage` antes de automatizar porque los identificadores exactos dependen de propiedad, profundidad y estadístico. La documentación WCS oficial muestra esta estructura de cobertura. [19]

Para Google Earth Engine, la documentación de ISRIC proporciona los scripts de exportación; el catálogo SoilGrids contiene las propiedades y profundidades correspondientes. [20]

Para agua disponible, las capas de contenido volumétrico permiten aproximar:

$$AWC_i = (\theta_{FC,i} - \theta_{WP,i})\, D_i$$

donde D_i es el espesor de capa en mm. Sumando:

$$AWC_{0-60} = \sum_{i \in [0,60cm]} (\theta_{33kPa,i} - \theta_{1500kPa,i}) D_i.$$

SoilGrids ofrece contenidos de agua a varias tensiones (`wv0033`, `wv1500`, etc.), por lo que puede construirse AWC directamente después de aplicar los factores de escala indicados en la documentación de ISRIC. [21]

Yo extraería para cada parcela:

$$clay_{0-30},\ sand_{0-30},\ SOC_{0-30},\ pH_{0-30},\ BD_{0-30},\ AWC_{0-30},\ AWC_{0-60}$$

más `AWC_0_60 × precip_fill` y `AWC_0_60 × VPD_fill`. Los **interacciones suelo×clima** son probablemente más útiles que la textura por sí sola.

OpenLandMap también es accesible mediante Earth Engine. El catálogo contiene capas nominalmente a ~250 m; por ejemplo, la clasificación de textura USDA puede consultarse mediante:

```
ee.Image("OpenLandMap/SOL/SOL_TEXTURE-CLASS_USDA-TT_M/v02")
```

y el catálogo incluye productos de arcilla, arena, densidad aparente, SOC, pH y contenido de agua. [22]

No aconsejo duplicar SoilGrids y OpenLandMap indiscriminadamente. Extraiga ambas fuentes, compare correlaciones y conserve la de mayor consistencia local, o use el desacuerdo entre productos como indicador de incertidumbre.

Para México, la capa nacional que pude verificar oficialmente es **Conjunto de Datos Vectorial Edafológico, escala 1:250 000, Serie II, Continuo Nacional** de INEGI. INEGI ofrece la ficha nacional y CONABIO documenta cobertura para las 32 entidades. [23]

Ficha oficial:

`https://www.inegi.org.mx/app/biblioteca/ficha.html?upc=794551131916`

Una precisión importante: **no asumiría que existe una "Serie IV de Edafología" equivalente a las series de Uso del Suelo y Vegetación sin verificar la ficha oficial**. La referencia nacional edafológica que pude confirmar es Serie II. Para el reto, descargue el continuo nacional, recórtelo con la envolvente y haga `spatial join` de cada parcela con la unidad edáfica dominante.

Con $N = 138$, no conviene generar decenas de one-hot de unidades taxonómicas raras. Agrupe en variables agronómicas interpretables: suelo dominante, textura, presencia de fase física/química y, preferentemente, complemente con las variables continuas SoilGrids.

Radiación, VPD y evapotranspiración

NASA POWER ofrece una API REST diaria para datos solares y meteorológicos. La API permite consultas puntuales, entrega JSON/CSV/NetCDF y permite solicitar múltiples parámetros; la documentación advierte que se trata de productos de rejilla global, por lo que un punto no equivale a una estación dentro de la parcela. [24]

Ejemplo:

```
https://power.larc.nasa.gov/api/temporal/daily/point
?parameters=ALLSKY_SFC_SW_DWN,T2M,T2M_MAX,T2M_MIN,RH2M,WS2M,PS,PRECTOTCOR
R
&community=AG
&longitude=-98.45
&latitude=19.71
&start=20250401
&end=20251031
&format=JSON
```

Documentación:

```
https://power.larc.nasa.gov/docs/services/api/temporal/daily/
```

API:

```
https://power.larc.nasa.gov/api/temporal/daily/point
```

POWER mantiene un catálogo específico para la comunidad Agroclimatology y dispone de datos diarios desde principios de los años ochenta hasta fechas próximas al presente. [25]

No asumiría que `VPD` o ET_0 existen siempre como parámetros nativos con el nombre que uno espera en la versión actual de POWER. Es más reproducible descargar los componentes y calcularlos.

Para presión de vapor de saturación:

$$e_s(T) = 0.6108\exp\left(\frac{17.27T}{T+237.3}\right) \quad [kPa]$$

y

$$VPD = e_s - e_a.$$

Si se dispone de punto de rocío:

$$e_a = e_s(T_{dew}).$$

Para evapotranspiración de referencia FAO-56:

$$ET_0 = \frac{0.408\Delta(R_n - G) + \gamma \frac{900}{T + 273} u_2 (e_s - e_a)}{\Delta + \gamma(1 + 0.34u_2)}.$$

En POWER, `ALLSKY_SFC_SW_DWN` proporciona irradiación solar descendente; hay que respetar la unidad indicada por el servicio y convertir a MJ m^{-2} d^{-1} cuando se use FAO-56. La documentación de POWER permite solicitar esos parámetros directamente en la API diaria. [26]

NASA POWER es excelente para **contexto y extremos atmosféricos**, pero su rejilla es demasiado gruesa para explicar diferencias entre parcelas vecinas. No duplique una misma celda climatológica y la trate como cientos de mediciones independientes.

ERA5-Land es más potente si se necesita el balance hidroclimático completo. Copernicus lo distribuye a 0.1° sobre una rejilla regular, con resolución nativa de aproximadamente 9 km, frecuencia horaria y cobertura desde 1950 hasta casi el presente. También incorpora cuatro capas de suelo de 0–7, 7–28, 28–100 y 100–289 cm. [27]

Dataset:

`https://cds.climate.copernicus.eu/datasets/reanalysis-era5-land`

Variables que descargaría:

```
2m_temperature
2m_dewpoint_temperature
total_precipitation
surface_solar_radiation_downwards
10m_u_component_of_wind
10m_v_component_of_wind
surface_pressure
evaporation
potential_evaporation
volumetric_soil_water_layer_1
volumetric_soil_water_layer_2
```

El acceso se automatiza con `cdsapi`; el producto oficial admite GRIB y/o NetCDF según la petición. [27]

Mi jerarquía sería: **CHIRPS para precipitación**, ERA5-Land o estación para temperatura/humedad/radiación/viento, y NASA POWER como alternativa o variable de comprobación. No agregaría los tres como predictores duplicados de temperatura.

Estaciones SMN/CONAGUA

El portal oficial del Servicio Meteorológico Nacional ofrece un **KMZ y una lista descargable de EMAs**, y especifica que los sensores básicos incluyen

velocidad/dirección del viento, presión, temperatura, humedad relativa, radiación solar y precipitación. [28]

Portal:

```
https://smn.conagua.gob.mx/es/observando-el-tiempo/estaciones-meteorologicas-automaticas-ema-s
```

Para Chignahuapan, Calpulalpan, Apan y Tulancingo, no recomiendo codificar de memoria un nombre de estación: **la condición operativa y la red pueden cambiar**. El procedimiento reproducible es descargar el KMZ/lista vigente, cargarlo como puntos, proyectar parcelas a UTM 14N y seleccionar estaciones activas por distancia y diferencia altitudinal. La página de normales climatológicas del SMN, por ejemplo, registra estaciones dentro del municipio de Calpulalpan, pero una estación climatológica convencional no debe confundirse automáticamente con una EMA activa. [29]

SIAP como prior agronómico

El producto que interesa es **Cierre de la Producción Agrícola** de SIAP/SADER:

```
https://nube.siap.gob.mx/cierre_agricola/
```

El portal debe consultarse por:

```
Años: 2018–2024
Cultivo: Cebada grano
Estados: Puebla, Hidalgo, Tlaxcala
Municipio:
  Chignahuapan
  Singuilucan
  Almoloya
  Cuautepec de Hinojosa
  Emiliano Zapata
  Tepeapulco
  Apan
  Calpulalpan
  Nanacamilpa de Mariano Arista
Modalidad:
  Temporal
  Riego
Ciclo:
  Primavera–Verano
```

La importancia de separar temporal y riego es alta: mezclar ambos generaría un prior que no representa el régimen hídrico de las parcelas. Fuentes oficiales mexicanas confirman la importancia de la cebada maltera en el corredor de Apan/Hidalgo y el uso de estadísticas oficiales de superficie y producción para caracterizar esa región. [13]

No incluyo aquí una tabla numérica 2018–2024 porque el portal SIAP no fue accesible mediante el crawler de esta investigación y sería incorrecto inventar cifras. El uso correcto de esos datos en ML sería construir, **únicamente con 2018–2024**:

$$SIAP_{\mu,m} = \frac{1}{7}\sum_{y=2018}^{2024} Yield_{m,y},$$

$$SIAP_{CV,m} = \frac{\sigma(Yield_{m,y})}{\mu(Yield_{m,y})},$$

además de mediana, pendiente temporal y diferencia respecto a la media estatal. No utilice datos SIAP 2025: un agregado municipal del mismo año objetivo constituiría una fuente potencial de leakage.

Tampoco impondría los rendimientos SIAP como límites rígidos. "Cebada grano" no necesariamente representa exclusivamente cebada maltera con el mismo manejo que el reto. Úselos como **covariable histórica o prior débil**, no como verdad parcela por parcela.

Ingeniería de variables, nubes, fenometría y fusión de sensores

El error más costoso sería transformar los 107,666 registros básicos y los 47,804 Planet en centenares de variables del tipo `NDVI_julio_03`, `NDVI_julio_08`, `NDVI_julio_15`, etc. Con 138 etiquetas, eso produciría una matriz $p \gg N$ extremadamente inestable.

La meta debe ser:

> decenas de miles de observaciones → 30–80 rasgos candidatos → 20–40 rasgos finales.

Filtrado y suavizado

Primero debe realizarse **QA físico del píxel**, luego detección de outliers y finalmente reconstrucción temporal. No suavice primero y filtre nubes después.

Para Sentinel-2 conviene emplear máscara de nubes/sombras a nivel de píxel —SCL y/o probabilidad de nube—; para Landsat, `QA_PIXEL`/CFMask; para Planet, su máscara de calidad UDM/UDM2 cuando esté disponible. El porcentaje de nubosidad de la escena o de la parcela debe conservarse además como peso de confianza, pero no sustituye la máscara pixel-wise. La armonización HLS de NASA también integra corrección atmosférica, máscara de nubes/sombras, registro espacial, normalización BRDF y ajuste del bandpass espectral precisamente porque una simple concatenación de Landsat y Sentinel no garantiza equivalencia radiométrica. [30]

Después del QA, usaría un detector robusto tipo Hampel/MAD local:

$$MAD = median(|x_i - median(x)|)$$

y marcaría como potencial outlier observaciones con desviación excesiva respecto a la mediana temporal local, especialmente caídas instantáneas de NDVI incompatibles con observaciones inmediatamente anterior/posterior.

Entre los métodos de reconstrucción evaluados en la literatura destacan Savitzky–Golay, Whittaker, funciones gaussianas/asimétricas, doble logística y Fourier. Comparaciones sistemáticas muestran que no existe un único ganador universal; el método óptimo depende de frecuencia de observación, ruido, gaps y forma de la temporada. [31]

Para este reto priorizaría **Whittaker ponderado**, cuya formulación es:

$$\hat{z} = \underset{z}{\operatorname{argmin}} \left[\sum_t w_t \, (y_t - z_t)^2 + \lambda \sum_t (\Delta^2 z_t)^2 \right].$$

Los pesos w_t permiten utilizar directamente nubosidad, fracción de píxeles válidos y calidad del sensor. Esto es una ventaja enorme en junio–septiembre.

Orden recomendado:

Método	Papel en AgroCebada
Whittaker ponderado	**Primario**
Savitzky–Golay	Sensibilidad/benchmark sobre series regulares
Doble logística Beck	Excelente cuando existe una temporada unimodal clara
Armónicos/Fourier	Útil para series largas 2022–2025; menor prioridad para evento agrícola corto
Interpolación lineal	Sólo gaps pequeños
Spline cúbico	Con cautela; puede crear sobreoscilaciones

La doble logística de Beck es especialmente útil para estimar inicio/fin de temporada mediante funciones suaves de green-up y senescencia. [32]

En Python:

```
scipy.signal.savgol_filter      -> Savitzky-Golay
scipy.optimize.curve_fit        -> doble logística
pybaselines                     -> Whittaker / penalized smoothers
statsmodels / numpy.linalg      -> regresión armónica
scipy.interpolate               -> interpolación/splines
```

Una alternativa muy madura es TIMESAT; si se acepta una etapa fuera de Python, continúa siendo referencia en extracción fenológica. Para reproducibilidad completa en Python, Whittaker + `scipy.optimize` es suficiente.

Fenometrics que deben extraerse

Sea $V(t)$ una curva suavizada de NDVI, EVI, LAI o NDWI.

Defina:

$$V_{base} = P_{10}(V)$$

$$A = V_{peak} - V_{base}.$$

Entonces el inicio de temporada puede definirse, por ejemplo, al 20 % de amplitud:

$$SOS = \min\{t: V(t) \geq V_{base} + 0.2A\}.$$

Análogamente:

$$EOS = \max\{t: V(t) \geq V_{base} + 0.2A\}.$$

y:

$$LOS = EOS - SOS.$$

La integral temporal:

$$AUC = \int_{SOS}^{EOS} [V(t) - V_{base}]\, dt$$

o discretamente:

$$AUC \approx \sum_{i=1}^{n-1} \frac{V_i + V_{i+1}}{2} (t_{i+1} - t_i).$$

Las variables que extraería por índice son:

Familia	Métrica
Nivel	máximo, P90, mediana
Tiempo	SOS, fecha pico, EOS, duración
Amplitud	máximo − baseline
Crecimiento	pendiente green-up
Producción integrada	AUC total
Reproducción	AUC pre-pico / alrededor del pico
Llenado	**AUC pospico**
Senescencia	pendiente pospico
Estrés	caídas abruptas, mínimos NDWI, máximos MSI/NDDI
Calidad	número observaciones, gap máximo, nube media

La literatura de predicción de cereal indica que métricas fenológicas, integrales y señal alrededor de espigado/llenado suelen contener más información de rendimiento que una observación NDVI única. [15]

Especialmente importantes para cebada:

$$\text{greenup_rate} = \frac{V_{peak} - V_{SOS}}{t_{peak} - t_{SOS}}$$

y

$$\text{senescence_rate} = \frac{V_{EOS} - V_{peak}}{t_{EOS} - t_{peak}}.$$

Una senescencia pospico muy rápida debería, en igualdad de condiciones, asociarse a menor período de llenado y menor PMG. El calor durante llenado puede acortar fuertemente esa duración. [10]

Para NDWI/MSI/NDDI no me limitaría al valor máximo. Más útiles podrían resultar:

```
NDWI_min_boot_anthesis
NDWI_mean_grainfill
NDWI_drop_peak_to_fill
MSI_max_grainfill
NDDI_max_boot
stress_duration_NDWI
```

porque capturan **momento del estrés**, no sólo intensidad.

Integración climática por fenofase

Después de estimar SOS/pico/EOS, usaría las fechas satelitales para construir ventanas dinámicas. Por ejemplo:

```
vegetative = SOS → peak - 15 d
reproductive = peak - 15 d → peak + 10 d
grain_fill = peak + 10 d → EOS
```

y simultáneamente una versión basada en GDD. La intersección entre ambas aumenta robustez cuando no se dispone de fecha de siembra.

Dentro de cada ventana:

$$P_\phi = \sum_{d \in \phi} P_d$$

$$Rad_\phi = \sum_{d \in \phi} R_{s,d}$$

$$VPD_{\phi} = \frac{1}{n_{\phi}} \sum VPD_d$$

$$Heat35_{\phi} = \sum I(T_{\max,d} > 35)$$

$$Frost2_{\phi} = \sum I(T_{\min,d} < -2).$$

Esto convierte clima diario en aproximadamente 10–20 predictores fisiológicamente significativos.

Fusión Sentinel-2, Landsat y Planet

No recomendaría concatenar directamente:

```
Planet_NDVI = 0.78
Sentinel_NDVI = 0.78
Landsat_NDVI = 0.78
```

como si representaran mediciones idénticas. Las respuestas espectrales, PSF, resolución espacial, correcciones atmosféricas, geometría y mezcla de píxeles son distintas. NASA tuvo que desarrollar HLS específicamente para resolver parte de esos problemas entre Landsat y Sentinel-2 mediante co-registro, normalización BRDF y ajuste de banda espectral. [33]

Claverie et al. documentan HLS como una armonización explícita de OLI y MSI; no incluye Planet. DOI: **10.1016/j.rse.2018.09.002**. [34]

Mi arquitectura sería:

$$X = [X_{Planet}, X_{S2}, X_{Landsat/HLS}, X_{clima}, X_{suelo}, X_{topo}].$$

Pero cada X_{sensor} contiene **fenometrics propias**, no las observaciones brutas.

Por ejemplo:

```
planet_ndvi_peak
planet_ndvi_auc
planet_lai_auc_fill
planet_senescence_rate

s2_ndvi_peak
s2_evi_auc
s2_ndwi_fill

landsat_ndvi_peak
landsat_msi_fill
```

Esto constituye una **fusión tardía de rasgos** y es, para $N = 138$, mucho más segura.

Z-score por sensor:

$$z_{s,t} = \frac{x_{s,t} - \mu_s}{\sigma_s}$$

puede ayudar con anomalías relativas, pero **no armoniza físicamente** sensores. Elimina offset y escala lineal, pero no corrige diferencias no lineales ni mezcla espacial.

Una opción mejor cuando existen observaciones casi simultáneas es estimar:

$$VI_{S2} = \alpha_s + \beta_s VI_{sensor} + \epsilon$$

con pares de fechas separadas, por ejemplo, ≤ 2 días y baja nubosidad. Esta calibración debe hacerse por índice y comprobar residuos.

Para Sentinel-2/Landsat puede probarse HLS, pero hay una decisión específica del reto: HLS a 30 m mejora consistencia temporal a costa de perder la ventaja espacial de Sentinel-2 en parcelas muy pequeñas. Por tanto, mantendría **S2 a 10 m como rama primaria** y usaría HLS como experimento secundario, particularmente en parcelas grandes. HLS está diseñado precisamente para producir series temporalmente coherentes entre OLI y MSI. [35]

Efecto de tamaño de parcela

Debe añadirse:

$$A_i = \log(1 + \text{ha}_i)$$

y, para cada sensor:

$$N_{\text{pixels,eff}}$$

$$valid_fraction$$

$$cloud_fraction$$

$$boundary_fraction.$$

Idealmente se elimina un buffer interior para reducir contaminación de bordes. Para Planet pueden bastar pocos metros; para Sentinel-2 podría probarse 10 m; en Landsat un buffer de 30 m destruiría prácticamente las parcelas pequeñas, por lo que conviene, en esos casos, usar todos los píxeles con pesos por pureza o aceptar que Landsat aporta una señal regional, no estrictamente intraparcelaria.

Además del promedio zonal, conservaría:

$$median, \quad IQR, \quad P_{25}, \quad P_{75}$$

o al menos `_promedio` + `_std`. La heterogeneidad intraparcelaria puede ser una señal productiva real, pero cuatro estadísticas de cada índice×fecha crearían nuevamente alta dimensionalidad; deben condensarse temporalmente.

Modelado, reducción dimensional y validación espacial

Cómo resolver $p \gg N$

El primer paso de selección no debe ser Boruta. Debe ser la **biología**.

Partiría de unas 60–80 variables candidatas distribuidas aproximadamente así:

Familia	Presupuesto inicial
Fenología Planet	12–15
Sentinel-2	10–12
Landsat/HLS	5–8
Clima/GDD/estrés	12–15
Suelo	8–10
Topografía/geometría	5–7
Historia 2022–2024	5–8
SIAP	3–5

Posteriormente:

Filtrado de calidad. Eliminar variables casi constantes, con demasiados faltantes o sin significado agronómico.

Redundancia. Si

$$|r(X_i, X_j)| > 0.90$$

conservar sólo una de las variables salvo que exista una razón fisiológica para mantener ambas. Para relaciones no lineales puede usarse Spearman.

mRMR. Maximum Relevance Minimum Redundancy intenta maximizar información respecto a Y y minimizar redundancia:

$$\max \left[I(X;Y) - \frac{1}{|S|} \sum_{X_j \in S} I\,(X;X_j) \right].$$

Es particularmente útil aquí para reducir 60–80 variables a, por ejemplo, 25–40. El método clásico fue formalizado por Peng et al., DOI **10.1109/TPAMI.2005.159**.

ElasticNet. Para regresión:

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \left[\frac{1}{2N} ||y - X\beta||_2^2 + \lambda \left(\alpha ||\beta||_1 + \frac{1-\alpha}{2} ||\beta||_2^2 \right) \right].$$

El componente L1 selecciona y el L2 estabiliza predictores altamente correlacionados, precisamente la situación esperable entre NDVI, EVI, LAI y múltiples métricas climáticas. DOI de Zou & Hastie: **10.1111/j.1467-9868.2005.00503.x**.

No elegiría variables porque su coeficiente sea distinto de cero una sola vez. Calcularía **frecuencia de selección en las particiones espaciales**:

$$Stability_j = \frac{1}{K}\sum_{k=1}^{K} I\left(\beta_{j,k} \neq 0\right).$$

Una variable seleccionada en 5/5 folds es mucho más confiable que una elegida una sola vez.

Boruta/Boruta-SHAP es útil como auditoría no lineal, pero con 138 muestras y muchos predictores correlacionados puede ser inestable. Lo utilizaría únicamente **dentro del fold de entrenamiento**, nunca una vez sobre los 138 datos antes de validación. El Boruta original: DOI **10.18637/jss.v036.i11**.

La regla fundamental es:

> Imputación, escalado, selección y tuning deben ocurrir dentro de cada fold

Si se hace mRMR o ElasticNet sobre los 138 ejemplos antes de CV, la validación deja de ser independiente.

Modelos recomendados

Modelo	Idoneidad con N=138	Comentario
ElasticNet	**Muy alta**	benchmark obligatorio; estable e interpretable
Bayesian Ridge	Alta	excelente referencia para pocos datos
SVR-RBF	**Muy alta**	buena flexibilidad con muestras pequeñas
GPR	Alta tras reducción	incertidumbre natural; sensible a escala y dimensión
CatBoost	**Alta**	árboles poco profundos y fuerte regularización
XGBoost	Alta	muy competitivo si profundidad 2–4
Random Forest	Media–alta	robusto baseline, pero puede diluir señal con muchos rasgos
LightGBM	Media	muy potente, pero fácil de sobreajustar con 138 filas
Stacking profundo	Baja	demasiados grados de libertad

Modelo	Idoneidad con N=138	Comentario
Blend de 2–3 modelos	**Muy alta**	preferible al stacking complejo

ElasticNet/Bayesian Ridge deben ser benchmarks obligatorios. Si CatBoost aparentemente supera por 30–40 % a ElasticNet en un K-fold aleatorio pero sólo marginalmente en CV espacial, sospecharía que aprovechó proxies geográficos.

Para XGBoost probaría algo como:

```
max_depth:        2–4
learning_rate:    0.01–0.05
min_child_weight: 3–15
subsample:        0.60–0.90
colsample_bytree: 0.50–0.90
reg_lambda:       5–50
reg_alpha:        0–5
n_estimators:     200–1200 con early stopping
```

Para CatBoost:

```
depth:            3–5
learning_rate:    0.01–0.05
l2_leaf_reg:      5–50
iterations:       300–1200
```

No usaría profundidad 8–10 con este N.

Random Forest:

```
n_estimators:       500–1500
max_depth:          3–8
min_samples_leaf:   5–15
max_features:       0.3–0.7
```

El `min_samples_leaf` relativamente alto es más importante aquí que aumentar miles de árboles.

Para SVR, todos los predictores deben estandarizarse:

$$x' = \frac{x - \mu}{\sigma}.$$

Buscaría:

```
kernel = RBF
C = 0.1 – 100
epsilon = 0.05 – 0.40
gamma = scale + búsqueda log
```

GPR sería especialmente atractivo después de una reducción a aproximadamente 10–15 variables con kernel Matérn $3/2$ o $5/2$:

$$k(r) = \sigma_f^2 \left(1 + \frac{\sqrt{3}r}{l}\right) \exp\left(-\frac{\sqrt{3}r}{l}\right)$$

más `WhiteKernel` para absorber error de reporte de rendimiento.

Con 138 observaciones, GPR no tiene un problema computacional; el problema es **estadístico** si se permite un length-scale independiente para 60 variables.

Validación espacial exacta

La validación aleatoria clásica supone que train y validation son aproximadamente independientes. Aquí eso falla porque parcelas vecinas comparten:

$$clima,\ suelo,\ elevación,\ manejo\ regional,\ sensores,\ fechas.$$

Roberts et al. demuestran que ignorar estructuras espaciales, temporales o jerárquicas puede subestimar seriamente el error predictivo. DOI **10.1111/ecog.02881**. [36]

Proyectaría centroides desde EPSG:4326 a **UTM 14N, EPSG:32614** y formaría grupos geográficos.

No usaría municipio como única validación primaria. Existe un problema grave de desequilibrio: Chignahuapan contiene 71 de las 138 parcelas de entrenamiento; un `LeaveOneMunicipalityOut` dejaría en un fold más de la mitad de la muestra.

Mi diseño recomendado:

Validación primaria: cinco bloques geográficos.

Crear 5 clusters de coordenadas mediante k-means espacial o agrupamiento jerárquico, intentando que cada bloque contenga aproximadamente 20–35 parcelas y que parcelas muy próximas no queden a ambos lados del límite.

Posteriormente:

```
GroupKFold(n_splits=5)
groups = spatial_cluster_id
```

La literatura de `blockCV` formaliza precisamente la construcción de folds espacialmente separados; referencia: Valavi et al. (2019), DOI **10.1111/2041-210X.13107**. La literatura reciente vuelve a remarcar que tamaño y geometría de los bloques modifican sustancialmente la estimación del error. [37]

Una versión aún mejor es estimar primero el rango de autocorrelación de rendimiento o residuos mediante variograma y elegir bloques cuyo diámetro sea comparable o mayor que ese rango.

Tuning interno:

$$Outer\colon\ 5\ folds\ espaciales$$

$$Inner\colon\ 3\ folds\ de\ grupos$$

en los cuatro bloques restantes.

Esta es una validación anidada. Hyperparameters, selección de variables y ensemble weights se ajustan exclusivamente dentro del outer-train.

Stress test regional: leave-one-state-out.

Tres experimentos:

```
train Hidalgo + Tlaxcala → test Puebla
train Puebla + Tlaxcala  → test Hidalgo
train Puebla + Hidalgo   → test Tlaxcala
```

No representan exactamente el test oculto —porque éste contiene los tres estados—, pero son extremadamente útiles para detectar un modelo que únicamente aprendió "Puebla alto / Tlaxcala bajo".

Mi criterio de selección sería combinar:

$$RMSE_{\text{spatial5}}$$

con

$$RMSE_{\text{state holdout}}$$

y dispersión entre folds. Preferiría un modelo con RMSE 0.50 t/ha estable en todos los folds frente a uno con 0.40 t/ha medio pero 0.25–0.90 dependiendo de la región.

También compararía dos versiones:

$$M_1 = X_{\text{biofísico}}$$

$$M_2 = X_{\text{biofísico}} + \text{estado/municipio/coordenadas.}$$

Si M_2 mejora drásticamente K-fold local pero colapsa leave-state-out, el incremento es probablemente un atajo geográfico.

Métricas

RMSE:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}.$$

Es especialmente apropiado si errores grandes son muy costosos.

MAE:

$$MAE = \frac{1}{n}\sum_{i=1}^{n} |\, y_i - \hat{y}_i|.$$

Es más robusto ante outliers/errores extremos de reporte.

Coeficiente de determinación:

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}.$$

En validación espacial puede ser negativo; eso no es un bug: significa que el modelo es peor que predecir la media del conjunto validado.

MAPE:

$$MAPE = \frac{100}{n}\sum_{i=1}^{n} \left|\frac{y_i - \hat{y}_i}{y_i}\right|.$$

Aquí el problema de división por cero no existe porque los rendimientos observados son ≥2 t/ha, pero MAPE da proporcionalmente más peso a parcelas de menor rendimiento. Por eso lo emplearía como métrica secundaria.

Muy importante: calcularía RMSE, MAE y R^2 sobre el **vector OOF completo**:

$$\{\hat{y}_1^{OOF}, \ldots, \hat{y}_{138}^{OOF}\}$$

y no promediaría R^2 entre folds pequeños.

Además reportaría errores por estado:

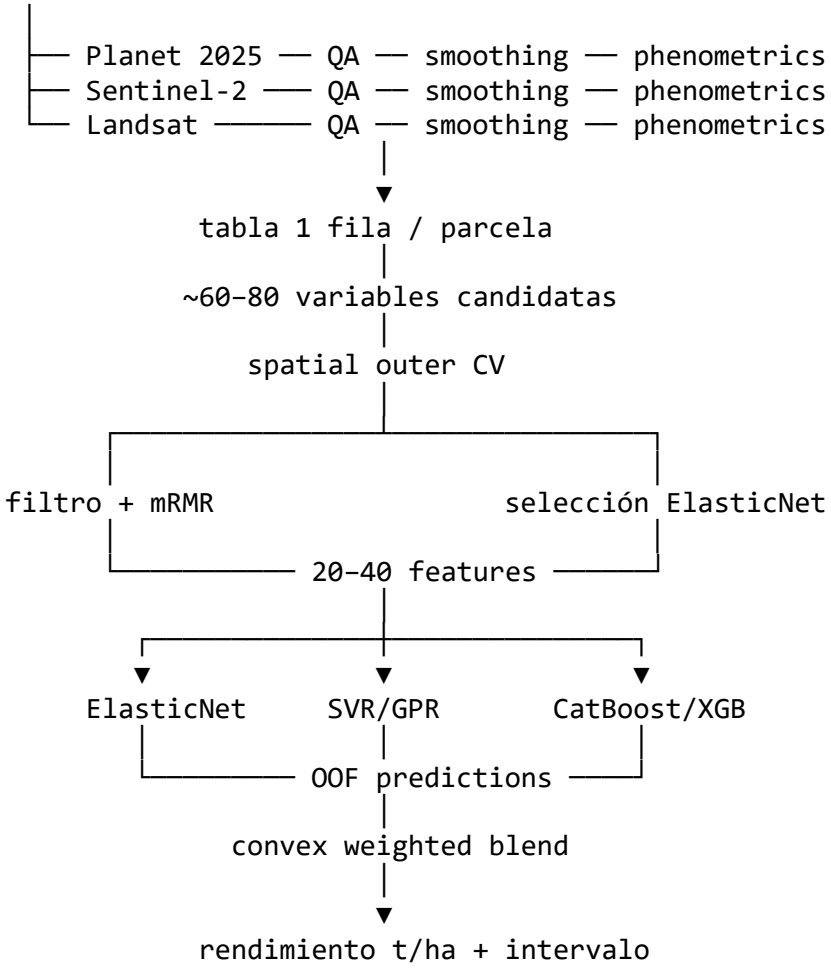
```
RMSE_Puebla
RMSE_Hidalgo
RMSE_Tlaxcala
```

y por tercil de superficie. Un buen score global podría ocultar errores sistemáticos precisamente en Tlaxcala.

Arquitectura final, XAI, control biológico y referencias prioritarias

La implementación que considero óptima puede resumirse como el siguiente flujo:

```
Polígonos
    │
    ├── Geometría / CEM
    ├── SoilGrids + INEGI
    ├── CHIRPS + ERA5-Land / POWER / SMN
```



El ensamble puede calcularse como:

$$\hat{y} = w_1\hat{y}_{Elastic} + w_2\hat{y}_{SVR} + w_3\hat{y}_{Cat}$$

con:

$$w_j \geq 0, \qquad \sum_j w_j = 1$$

y los pesos escogidos para minimizar RMSE **exclusivamente sobre predicciones OOF espaciales**. Con 138 parcelas, esta restricción convexa es preferible a entrenar un meta-modelo complejo.

Una combinación inicial razonable a probar, no a fijar a priori, sería que el modelo lineal aporte estabilidad, CatBoost/XGBoost las interacciones no lineales suelo×clima y SVR/GPR la respuesta continua suave.

Auditoría SHAP

SHAP permite descomponer:

$$\hat{y}_i = E[f(X)] + \sum_{j=1}^{p} \phi_{ij}$$

donde ϕ_{ij} representa la contribución del predictor j a la predicción de la parcela i. Para árboles, TreeSHAP permite una implementación eficiente y con propiedades consistentes; Lundberg et al. formalizaron su uso para interpretabilidad de modelos de árboles. DOI **10.1038/s42256-019-0138-9**.

No calcularía SHAP únicamente sobre el modelo final entrenado con los 138 ejemplos. Calcularía también **SHAP sobre cada fold validado** y comprobaría estabilidad de signos.

La auditoría agronómica debería exigir aproximadamente:

Predictor	Relación esperable	Bandera roja
AUC NDVI/LAI llenado	positiva hasta saturación	gran efecto negativo sin explicación
senescence_rate rápida	negativa	fuerte efecto positivo
NDWI en reproducción	generalmente positiva	monotonicidad negativa universal
días Tmax >35 °C en llenado	negativa	efecto consistentemente positivo
heladas en embuche/antesis	negativa	efecto positivo
radiación útil llenado	positiva si agua adecuada	efecto incondicional enorme
AWC	positiva bajo déficit; posible saturación	señal extrema sin interacción
nube media	debería tener poco efecto	predictor principal
ESTADO	residual/moderado	predictor dominante absoluto
área	posible efecto pequeño	domina NDVI/clima
pixel_count	calidad, no productividad	gran predictor de rendimiento

Una dependencia SHAP razonable para temperatura podría ser no lineal:

$$\phi(T) \approx \begin{cases} \text{positivo/neutro}, & T \text{ moderada} \\ 0 \rightarrow \text{negativo}, & T \approx 26 - 30^{\circ}C \\ \text{fuertemente negativo}, & T > 32 - 35^{\circ}C. \end{cases}$$

La literatura de cebada respalda precisamente el deterioro reproductivo y de llenado bajo temperaturas elevadas. [4]

El chequeo más poderoso sería reconstruir implícitamente la identidad del rendimiento. Si SHAP indica:

```
más macollamiento/vigor temprano
+ persistencia LAI
+ agua durante reproducción
+ AUC de llenado
- calor
- senescencia prematura
→ mayor rendimiento
```

el modelo es biológicamente coherente.

Si, en cambio:

```
estado=Puebla
+ longitud
+ ID de municipio
+ porcentaje de nube
→ mayor rendimiento
```

aunque tenga un CV aleatorio espectacular, no es un modelo que deba considerarse robusto.

Variables finales que probablemente merezcan entrar

Una configuración final compacta podría contener, aproximadamente:

```
planet_ndvi_peak
planet_peak_doy
planet_ndvi_auc_total
planet_ndvi_auc_postpeak
planet_lai_peak
planet_lai_auc_fill
planet_ndwi_fill
planet_senescence_rate
planet_growth_rate

s2_ndvi_peak
s2_evi_auc
s2_ndwi_min_reproductive
s2_lai_peak

landsat_msi_fill
landsat_nddi_peak

gdd_sos_peak
gdd_peak_eos
```

```
precip_vegetative
precip_reproductive
precip_fill
cdd_reproductive
vpd_reproductive
vpd_fill
radiation_fill
et0_minus_p_fill
days_tmax30_reproductive
days_tmax35_fill
days_tmin0_reproductive
days_tmin_minus2_reproductive

awc_0_30
awc_0_60
clay_0_30
soc_0_30
ph_0_30
bulk_density_0_30

elevation
slope
log_area
effective_s2_pixels
effective_landsat_pixels

historical_peak_ndvi_2022_2024
historical_auc_cv
siap_yield_median_2018_2024
```

No todos deben sobrevivir. Son **candidatos** para selección nested-CV.

Particularmente útiles pueden ser las interacciones:

$$AWC \times P_{fill}$$

$$VPD_{fill} \times AWC$$

$$Heat35_{fill} \times NDWI_{fill}$$

$$Radiation_{fill} \times NDWI_{fill}.$$

Los árboles pueden aprenderlas implícitamente; para ElasticNet/SVR vale la pena construir sólo unas pocas interacciones con justificación fisiológica.

Cómo usar 2022–2024 sin inducir ruido

Las series antiguas son valiosas como “firma productiva del sitio”, pero sólo si se interpretan correctamente. Si no se conoce qué cultivo ocupó cada polígono en

2022–2024, no debería compararse directamente un `NDVI_2023_julio` con la cebada 2025.

Construiría rasgos robustos:

$$historical_peak = median(peak_{2022}, peak_{2023}, peak_{2024})$$

$$historical_CV = \frac{SD(AUC_{2022:2024})}{mean(AUC_{2022:2024})}$$

y `2025_anomaly = AUC_2025 - historical_median`, siempre que las curvas antiguas demuestren una temporada agrícola comparable.

Eso permite que el modelo distinga una parcela intrínsecamente productiva de un año excepcional.

Orden práctico de experimentación

En lugar de correr decenas de algoritmos desde el principio, utilizaría una escalera de ablation experiments:

Experimento	Features	Pregunta
Baseline	media global	dificultad mínima
Regional	estado/municipio	cuánto rendimiento explica geografía
Topo+suelo	CEM + SoilGrids	capacidad edáfica
Climate	+ GDD/agua/calor	efecto meteorológico
Satellite S2	+ fenología S2	señal de cultivo
Planet	+ fenología Planet	valor de alta frecuencia/resolución
Full bio	todo excepto administración	generalización fisiológica
Full geo	full bio + estado/coords	valor incremental de ubicación
Ensemble	mejores 2–3	estabilidad final

El resultado decisivo será la diferencia entre `Full bio` y `Full geo`. Mi objetivo sería que **Full bio explique la mayor parte de la brecha regional**, dejando a estado/coordenadas sólo un residuo.

Finalmente, no impondría:

$$2.00 \leq \hat{y} \leq 5.59$$

sólo porque ése sea el rango de entrenamiento. El test puede legítimamente contener un rendimiento fuera del rango observado. Si se utiliza clipping, debería ser un límite agronómico amplio y validado, no `min/max(train)`.

Fuentes y referencias bibliográficas prioritarias

Referencia	Utilidad	DOI / repositorio

Referencia	Utilidad	DOI / repositorio
Cammarano et al. (2021), modelado de cebada / CERES-Barley	desarrollo térmico y manejo	**10.3389/fpls.2021.655406** [38]
Shirdelmoghanloo et al. (2022), *Frontiers in Plant Science*	calor y llenado/calidad del grano	**10.3389/fpls.2022.858652** [10]
Samarah (2005), sequía en cebada	componentes de rendimiento	**10.1051/agro:2004064** [39]
Beck et al. (2006), Remote Sensing of Environment	doble logística fenológica	**10.1016/j.rse.2005.10.021** [32]
Cai et al. (2017), *Remote Sensing*	comparación de smoothing	**10.3390/rs9121271** [40]
Eilers (2003), *Analytical Chemistry*	Whittaker smoothing	**10.1021/ac034173t**
Ji et al. (2021), *Sensors*	phenometrics para yield	**10.3390/s21041406** [41]
Claverie et al. (2018), RSE	armonización Landsat/Sentinel-2	**10.1016/j.rse.2018.09.002** [42]
Roberts et al. (2017), *Ecography*	spatial CV	**10.1111/ecog.02881** [36]
Valavi et al. (2019), *Methods Ecol. Evol.*	spatial blocking	**10.1111/2041-210X.13107** [43]
Poggio et al. (2021), *SOIL*	SoilGrids 2.0	**10.5194/soil-7-217-2021** [44]
Muñoz-Sabater et al. (2021), ESSD	ERA5-Land	**10.5194/essd-13-4349-2021** [27]
Funk et al. (2015), *Scientific Data*	CHIRPS	**10.1038/sdata.2015.66**
Zou & Hastie (2005)	ElasticNet	**10.1111/j.1467-9868.2005.00503.x**
Peng et al. (2005)	mRMR	**10.1109/TPAMI.2005.159**
Kursa & Rudnicki (2010)	Boruta	**10.18637/jss.v036.i11**
Lundberg et al. (2020), *Nature Machine Intelligence*	TreeSHAP	**10.1038/s42256-019-0138-9**

Repositorios operativos prioritarios:

SoilGrids / ISRIC:
`https://soilgrids.org/`

https://maps.isric.org/
https://files.isric.org/soilgrids/latest/data/
La documentación oficial confirma la resolución de 250 m, las profundidades y las propiedades disponibles. [45]

OpenLandMap / Google Earth Engine:
https://developers.google.com/earth-engine/datasets/tags/openlandmap
El catálogo incluye productos edáficos globales, en gran parte a 250 m. [46]

INEGI Edafología Serie II, Continuo Nacional 1:250 000:
https://www.inegi.org.mx/app/biblioteca/ficha.html?upc=794551131916 [47]

NASA POWER:
https://power.larc.nasa.gov/api/temporal/daily/point
https://power.larc.nasa.gov/docs/services/api/temporal/daily/ [24]

ERA5-Land / Copernicus CDS:
https://cds.climate.copernicus.eu/datasets/reanalysis-era5-land [27]

CONAGUA / SMN – EMAs:
https://smn.conagua.gob.mx/es/observando-el-tiempo/estaciones-meteorologicas-automaticas-ema-s [28]

SIAP / SADER – Cierre agrícola:
https://nube.siap.gob.mx/cierre_agricola/

La conclusión técnica central es que el mejor modelo para AgroCebada 2026 no debería "predecir Puebla, Hidalgo o Tlaxcala". Debe aprender una cadena causal aproximada:

suelo + agua + temperatura + radiación → establecimiento/macollamiento → fertilidad de espiga →

y utilizar la información espacial sólo para completar, no reemplazar, esa explicación. Con apenas 138 etiquetas, la ganancia de precisión más probable no vendrá de añadir más capas indiscriminadamente, sino de **reducir miles de observaciones a unas pocas métricas fenológicas y de estrés de alta calidad, validar espacialmente y exigir que la explicación SHAP sea compatible con la fisiología de la cebada**.

---

[1] [36] https://findanexpert.unimelb.edu.au/scholarlywork/1186691-cross-validation-strategies-for-data-with-temporal--spatial--hierarchical--or-phylogenetic-structure

https://findanexpert.unimelb.edu.au/scholarlywork/1186691-cross-validation-strategies-for-data-with-temporal--spatial--hierarchical--or-phylogenetic-structure

[2] [11] [39] https://hal.science/hal-00886257v1/document

https://hal.science/hal-00886257v1/document

[3] [8] [9] [38] Genetic and Management Effects on Barley Yield ...

https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2021.655406/full?utm_source=chatgpt.com

[4] [6] https://pmc.ncbi.nlm.nih.gov/articles/PMC11314375/

https://pmc.ncbi.nlm.nih.gov/articles/PMC11314375/

[5] https://link.springer.com/article/10.1186/s12870-025-07504-8

https://link.springer.com/article/10.1186/s12870-025-07504-8

[7] [10] https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2022.858652/full

https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2022.858652/full

[12] https://www.ndsu.edu/agriculture/ag-hub/ag-topics/crop-production/crops/barley/small-grain-damage-frost-dependent-many-factors

https://www.ndsu.edu/agriculture/ag-hub/ag-topics/crop-production/crops/barley/small-grain-damage-frost-dependent-many-factors

[13] Cebada maltera en la región de Apan, Hidalgo.

https://www.gob.mx/agricultura/hidalgo/articulos/cebada-maltera-en-la-region-de-apan-hidalgo?idiom=es&utm_source=chatgpt.com

[14] Evaluación agronómica y física en líneas avanzadas de cebada ...

https://www.scielo.org.mx/article_plus.php?lng=es&pid=S2007-09342016000100159&tlng=es&utm_source=chatgpt.com

[15] [41] https://www.mdpi.com/1424-8220/21/4/1406

https://www.mdpi.com/1424-8220/21/4/1406

[16] https://wmo.int/es/media/news/la-organizacion-meteorologica-mundial-advierte-de-la-creciente-probabilidad-de-formacion-de-un

https://wmo.int/es/media/news/la-organizacion-meteorologica-mundial-advierte-de-la-creciente-probabilidad-de-formacion-de-un

[17] [44] SoilGrids Documentation

https://docs.isric.org/globaldata/soilgrids/SoilGrids_faqs.html?utm_source=chatgpt.com

[18] Access WMS with ArcMap and QGIS – SoilGrids ...

https://docs.isric.org/globaldata/soilgrids/wms_from_qgis_arcmap.html?utm_source=chatgpt.com

[19] WCS - SoilGrids Documentation

https://docs.isric.org/globaldata/soilgrids/wcs.html?utm_source=chatgpt.com

[20] SoilGrids on Google Earth Engine (GEE)

https://docs.isric.org/globaldata/soilgrids/access_on_gee.html?utm_source=chatgpt.com

[21] [45] SoilGrids layers

https://docs.isric.org/globaldata/soilgrids/SoilGrids_faqs_01.html?utm_source=chatgpt.com

[22] OpenLandMap Soil Texture Class (USDA System)

https://developers.google.com/earth-engine/datasets/catalog/OpenLandMap_SOL_SOL_TEXTURE-CLASS_USDA-TT_M_v02?utm_source=chatgpt.com

[23] [47] https://www.inegi.org.mx/app/biblioteca/ficha.html?upc=794551131916

https://www.inegi.org.mx/app/biblioteca/ficha.html?upc=794551131916

[24] [25] [26] https://power.larc.nasa.gov/docs/services/api/temporal/daily/

https://power.larc.nasa.gov/docs/services/api/temporal/daily/

[27] https://cds.climate.copernicus.eu/datasets/reanalysis-era5-land?tab=overview

https://cds.climate.copernicus.eu/datasets/reanalysis-era5-land?tab=overview

[28] https://smn.conagua.gob.mx/es/observando-el-tiempo/estaciones-meteorologicas-automaticas-ema-s

https://smn.conagua.gob.mx/es/observando-el-tiempo/estaciones-meteorologicas-automaticas-ema-s

[29] https://smn.conagua.gob.mx/es/climatologia/informacion-climatologica/normales-climatologicas-por-estado?estado=tlax

https://smn.conagua.gob.mx/es/climatologia/informacion-climatologica/normales-climatologicas-por-estado?estado=tlax

[30] [33] [35] [42] https://modis.gsfc.nasa.gov/sci_team/pubs/abstract_new.php?id=27008

https://modis.gsfc.nasa.gov/sci_team/pubs/abstract_new.php?id=27008

[31] https://www.sciencedirect.com/science/article/abs/pii/S0034425715302443

https://www.sciencedirect.com/science/article/abs/pii/S0034425715302443

[32] https://www.sciencedirect.com/science/article/abs/pii/S0034425705003640

https://www.sciencedirect.com/science/article/abs/pii/S0034425705003640

[34] https://www.sciencedirect.com/science/article/pii/S0034425718304139

https://www.sciencedirect.com/science/article/pii/S0034425718304139

[37] https://www.frontiersin.org/journals/remote-sensing/articles/10.3389/frsen.2025.1531097/full

https://www.frontiersin.org/journals/remote-sensing/articles/10.3389/frsen.2025.1531097/full

[40] https://www.mdpi.com/2072-4292/9/12/1271

https://www.mdpi.com/2072-4292/9/12/1271

[43] https://github.com/xarray-contrib/xbatcher/discussions/78

https://github.com/xarray-contrib/xbatcher/discussions/78

[46] Datasets tagged openlandmap in Earth Engine

https://developers.google.com/earth-engine/datasets/tags/openlandmap?utm_source=chatgpt.com