Estrategia de Modelado Predictivo de Rendimiento de Cebada Maltera para el Altiplano Central Mexicano

La estimación precisa del rendimiento de cebada maltera (*Hordeum vulgare*) a escala parcelaria en el Altiplano Central de México plantea un problema de inferencia estadística en un régimen de alta dimensionalidad con escasez muestral ($N = 138$ parcelas en calibración frente a más de 300 predictores potenciales, $p \gg N$). La heterogeneidad productiva observada en los datos—donde Chignahuapan (Puebla) alcanza un promedio de 4.48 t/ha frente a los Llanos de Apan (Hidalgo) con 3.76 t/ha y Calpulalpan (Tlaxcala) con 2.98 t/ha—no constituye un ruido estocástico, sino la manifestación directa de discontinuidades edafoclimáticas y orográficas pronunciadas[1]. La interacción entre la sombra orográfica de la Sierra Madre Oriental, la presencia de horizontes subsuperficiales endurecidos (tepetates) y la dinámica de evapotranspiración durante las etapas reproductivas modula de forma determinante el potencial biológico del cultivo[3].

Para maximizar el poder de generalización sobre el conjunto de prueba ($N = 59$ parcelas) y mitigar el sobreajuste (*overfitting*), la formulación analítica óptima descarta la alimentación directa de índices espectrales brutos en arquitecturas complejas de aprendizaje profundo. La solución metodológica se estructura en una tubería modular compuesta por:

1. Reconstrucción analítica de perfiles satelitales ópticos mediante el filtro de Whittaker-Eilers penalizado y ponderado por calidad radiométrica;
2. Extracción de métricas fenológicas cuantitativas centradas en la integral temporal de llenado de grano y el pico vegetativo;
3. Fusión espectral armonizada entre Sentinel-2 y Landsat mediante coeficientes HLS, manteniendo a PlanetScope en una rama paralela de alta frecuencia;
4. Enriquecimiento edafoclimático mediante la integración vía API de SoilGrids v2.0, cartografía edafológica de INEGI, reanálisis de radiación y déficit de presión de vapor (VPD) de NASA POWER y ERA5-Land, junto con calibración histórica del SIAP[5];
5. Selección jerárquica de características basada en Relevancia Máxima y Redundancia Mínima (mRMR) confirmada por Boruta-SHAP[9];
6. Protocolo riguroso de validación cruzada espacial agrupada (GroupKFold municipal con zona de amortiguamiento) para neutralizar la fuga de datos por autocorrelación geográfica[11]; y
7. Un ensamble por apilamiento (*Stacking*) de baja complejidad que combina Procesos Gaussianos con kernel de determinación automática de relevancia (ARD), regresión ElasticNet y CatBoost regularizado, auditado mediante análisis de atribución biofísica con valores SHAP[13].

Fenología Agronómica de Hordeum vulgare y Determinación de Componentes del Rendimiento

El desarrollo de la cebada maltera de temporal en los Valles Altos de México (altitudes de 2,200 a 2,700 m s.n.m.) abarca un ciclo vegetativo de 90 a 130 días, regulado por la variedad sembrada (comúnmente genotipos de dos hileras como Esmeralda, Adabella o Alina) y la disponibilidad térmica e hídrica estival[2]. La ventana de siembra agronómicamente recomendada comprende del 15 de mayo al 20 de junio, permitiendo que la fase de emergencia coincida con el establecimiento pleno del temporal de lluvias[1].

Fase Fenológica	Escala Zadoks	Ventana Temporal Típica	Dinámica Morfogenética y Fisiológica	Factores Críticos de Estrés Abiótico
Germinación y Emergencia	Z00 – Z19	Días 0 – 12 post-siembra	Imbibición, protrusión radicular, emergencia del coleóptilo y despliegue de las dos primeras hojas	Déficit hídrico en los primeros 5 cm; sellado y encostramiento superficial del suelo
Amacollamiento (Macollamiento)	Z20 – Z29	Días 13 – 35 post-siembra	Desarrollo de tallos secundarios axilares; iniciación del sistema radicular coronal o adventicio	Deficiencia de fósforo disponible; sequía moderada temprana; competencia por malezas
Encañado (Elongación de tallos)	Z30 – Z39	Días 36 – 60 post-siembra	Elongación rápida de entrenudos; diferenciación del primordio floral dentro de la vaina	Estrés hídrico severo; estrés térmico (> 26 °C); deficiencia de nitrógeno

			foliar	
Espigado y Antesis (Floración)	Z50 – Z69	Días 61 – 75 post-siembra	Emergencia completa de la espiga (Z58); polinización y fecundación de espiguillas fértiles (Z65)	Temperaturas máximas > 28 °C; heladas tardías (< -1 °C); estrés por sequía
Llenado de Grano	Z70 – Z89	Días 76 – 105 post-siembra	Translocación de carbohidratos solubles del tallo y asimilados fotosintéticos hacia el endospermo	Temperaturas diurnas > 32 °C; sequía terminal; déficit de presión de vapor elevado
Maduración Fisiológica	Z90 – Z92	Días 106 – 125 post-siembra	Cese de acumulación de materia seca; pérdida activa de humedad del grano hasta niveles inferiores al 14%	Precipitaciones excesivas que induzcan germinación en espiga; granizadas severas

Dinámica Térmica y Formulación de Grados Día de Desarrollo

La tasa de organogénesis y la transición entre estadios fenológicos responden a la acumulación de calor metabólicamente útil, cuantificado a través de los Grados Día de Desarrollo (GDD)[18]. Para genotipos de cebada adaptados a los Valles Altos, las temperaturas cardinales de calibración corresponden a:

- Temperatura base (T_{base}): 0 °C (con un umbral funcional mínimo en el rango de 0 °C a 4 °C)[18];

- Temperatura óptima (T_{opt}): 15 °C a 20 °C, donde la fotosíntesis y el crecimiento exhiben su máxima eficiencia metabólica;
- Temperatura máxima o umbral de corte superior (T_{corte} o T_{upper}): 32 °C, punto en el que se inducen respuestas de choque térmico y desactivación de la rubisco sintetasa.

La acumulación térmica diaria se modela mediante el método agronómico estándar de doble corte simétrico para neutralizar oscilaciones anómalas:

$$T^*_{\text{max},t} = \min\left(\max(T_{\text{max},t}, T_{\text{base}}), T_{\text{upper}}\right)$$

$$T^*_{\text{min},t} = \max\left(\min(T_{\text{min},t}, T_{\text{upper}}), T_{\text{base}}\right)$$

$$\text{GDD}_t = \max\left(\frac{T^*_{\text{max},t} + T^*_{\text{min},t}}{2} - T_{\text{base}}, 0\right)$$

$$\text{GDD}_{\text{acum}} = \sum_{t=t_{\text{siembra}}}^{t_{\text{fase}}} \text{GDD}_t$$

En variedades malteras primaverales de ciclo intermedio en México, la emergencia requiere entre 100 y 130 GDD; el amacollamiento pleno demanda de 350 a 450 GDD; el encañado se desarrolla en el intervalo de 500 a 850 GDD; la antesis ocurre entre 950 y 1,050 GDD; y la madurez fisiológica completa se consolida entre 1,450 y 1,650 GDD acumulados desde la siembra[15].

Ontogenia y Ventanas Temporales de los Componentes Numéricos del Rendimiento

El rendimiento final de grano por unidad de superficie (Y, en t/ha) se descompone en tres variables biológicas estructuradas cronológicamente[2]:

$$Y = \left(\frac{\text{Espigas}}{\text{m}^2}\right) \times \left(\frac{\text{Granos}}{\text{Espiga}}\right) \times \left(\frac{\text{PMG}}{1000}\right) \times 10^{-4}$$

donde PMG representa el Peso de Mil Granos expresado en gramos[17].

El número de espigas por metro cuadrado se determina desde el amacollamiento hasta el inicio del encañado (Zadoks 22 a 31). La tasa de supervivencia de macollos fértiles depende de la nutrición nitrogenada, la humedad en los primeros 30 cm de suelo y la radiación solar

interceptada[2]. Episodios de sequía en esta ventana abrevian el macollamiento y causan la atrofia prematura de brotes secundarios.
El número de granos por espiga queda fijado en la fase de rápida elongación del tallo y floración (Zadoks 32 a 65), abarcando los 25 a 30 días previos a la antesis[18]. En este intervalo se define el número de espiguillas diferenciadas por raquis y la fertilidad del polen y óvulos. Déficits de humedad o caídas drásticas de radiación solar provocan aborto masivo de flores en las espiguillas proximales y distales.
El peso de mil granos (PMG) se construye de forma exclusiva pos-antesis durante el llenado de grano (Zadoks 71 a 89)[18]. Depende de la tasa fotosintética neta en la hoja bandera y aristas de la espiga, sumada a la eficiencia de removilización de carbohidratos solubles (fructanos) almacenados en los entrenudos del tallo hacia los granos en crecimiento[2].

Umbrales de Estrés Fisiológico y Riesgos por Heladas

El cultivo de cebada en los Valles Altos exhibe umbrales biofísicos críticos ante eventos térmicos e hídricos extremos:

Factor de Estrés	Etapa Fenológica Vulnerable	Umbral Crítico	Efecto Biofísico y Consecuencia Productiva
Estrés Térmico por Golpe de Calor	Floración / Antesis (Z60 – Z69)	Temperatura máxima $>$	Deshidratación y pérdida de viabilidad en granos de polen; aborto floral severo y espigas vacías[18]
Estrés Térmico Severo	Llenado de Grano (Z70 – Z85)	Temperatura máxima $>$	Inhibición de la almidón sintetasa; forzado prematuro de madurez; grano chupado con exceso de proteína[22]
Estrés Hídrico por Déficit	Encañado a Espigado (Z30 – Z55)	Humedad del suelo $<$ de agua disponible	Senescencia anticipada de hojas basales; reducción del índice de área foliar y aborto de espiguillas

Helada Tardía	Espigado a Floración (Z50 – Z65)	Temperatura mínima $<$	Muerte celular por congelamiento del tejido reproductivo; esterilidad total de espigas expuestas[3]
Helada Temprana	Llenado Tardío (Z80 – Z87)	Temperatura mínima $<$	Cese abrupto del transporte floemático al grano; reducción de PMG y caída drástica de viabilidad germinativa

Bases Agroecológicas de la Disparidad Regional de Rendimiento en Valles Altos

La disparidad productiva registrada en el universo de entrenamiento (Puebla: 4.48 t/ha; Hidalgo: 3.76 t/ha; Tlaxcala: 2.98 t/ha) responde a un gradiente geofísico bien diferenciado a lo largo del Altiplano Central:

Región Productiva y Municipio	Altitud Media (m s.n.m.)	Rendimiento Histórico (t/ha)	Régimen Hídrico Estival	Características Edafológicas Dominantes	Limitantes Agroecológicas de Mayor Impacto
Chignahuapan *(Puebla)*	2,250 – 2,600	4.48 (std 0.58)	Alto (650 – 850 mm); humedad orográfica	Andosoles mólicos y Phaeozoles eútricos; alto SOC (> 3.0%), textura franca, alta AWC	Exceso hídrico eventual en maduración; menor radiación por alta cobertura de nubosidad
Llanos de Apan /	2,450 –	3.76 (std	Medio (450 – 550 mm);	Phaeozoles háplicos y	Canícula acentuada;

Singuiluca n *(Hidalgo)*	2,580	0.78)	valles intermonta nos	Cambisoles eútricos; SOC moderado (1.5 – 2.2%), textura franca a arcillosa	vientos desecantes; eventos moderados de estrés térmico durante la antesis
Calpulalpa n / Nanacamil pa *(Tlaxcala)*	2,500 – 2,700	2.98 (std 0.38)	Bajo a Medio (400 – 500 mm); sombra de lluvia	Durisoles y Leptosoles someros; presencia de horizontes petrocálcic os y tepetates endurecido s[3]	Profundida d radicular restringida (< 40 cm); escasa retención hídrica; alta vulnerabilid ad a heladas

Mecanismos Biofísicos Subyacentes a la Diferencia de Productividad

Chignahuapan se encuentra emplazado en la ladera de sotavento inmediata de la Sierra Norte de Puebla, beneficiándose de advecciones continuas de humedad orográfica procedentes del Golfo de México. Esta condición favorece una humedad relativa media superior, una reducción del déficit de presión de vapor (VPD) atmosférico y precipitaciones acumuladas de 650 a 850 mm a lo largo del ciclo Primavera-Verano. En términos edáficos, dominan suelos derivados de cenizas volcánicas (Andosoles), dotados de una densidad aparente reducida ($< 0.95\ \mathrm{g/cm^3}$), contenidos de carbono orgánico superiores al 3% y una Capacidad de Agua Disponible (AWC) por encima del 20% volumétrico. Dicha matriz edáfica almacena suficiente agua útil para amortiguar pausas pluviométricas de más de dos semanas sin comprometer la hidratación del cultivo.

En contraste, Calpulalpan y los Llanos de Apan ocupan cuencas endorreicas protegidas por barreas montañosas que generan un efecto clásico de sombra de lluvia. La precipitación media acumulada durante el temporal difícilmente sobrepasa los 500 mm. La limitante agronómica en Tlaxcala radica en la severa degradación de los perfiles de suelo: la presencia generalizada de capas fragipánicas o petrocálcicas compactadas a escasa profundidad (tepetates endurecidos a 25–40 cm de la superficie) restringe el volumen de enraizamiento efectivo[3]. Como resultado, la capacidad total de almacenamiento de agua en el suelo explorado por la raíz cae por debajo de los 45 mm. Cuando cesa la lluvia por lapsos mayores a 8 o 10 días, el suelo agota rápidamente su reserva de agua disponible, induciendo el cierre estomático de la cebada,

reduciendo la asimilación neta de CO_2 e incrementando la tasa de aborto de espiguillas[4].

Comportamiento y Anomalías Climáticas Durante el Ciclo Agrícola 2025

El ciclo Primavera-Verano 2025 estuvo sujeto a anomalías macroclimáticas de relevancia en el Altiplano Central:

- **Fase de siembra (abril a mayo de 2025)**: Se caracterizó por temperaturas medias de 1.5 °C a 2.5 °C por encima de la media climatológica histórica, acompañadas de una sequía extrema que retrasó las siembras generalizadas hasta inicios de junio[4].
- **Fase de emergencia y macollamiento (junio de 2025)**: La entrada simultánea de sistemas de baja presión y depresiones tropicales en el Golfo de México generó el mes de junio más húmedo registrado en el país desde 1941, mitigando las condiciones de sequía en Hidalgo, Tlaxcala y Puebla[24]. Este aporte hídrico homogeneizó la germinación y propició densidades iniciales óptimas de plantas.
- **Fase reproductiva y canícula (julio a agosto de 2025)**: Se presentó un marcado desacoplamiento regional. Mientras que en Chignahuapan las precipitaciones se mantuvieron constantes con nieblas frecuentes, en Calpulalpan y los Llanos de Apan se observó una canícula severa con una reducción pluviométrica del 20% al 35% combinada con picos de temperatura máxima que superaron de manera recurrente los 29 °C[4]. En Tlaxcala, este estrés hídrico y térmico golpeó directamente la fase de antesis y llenado inicial, truncando la formación de granos por espiga y sellando la brecha de rendimiento inferior a 3.0 t/ha[4].

Catálogo e Integración Programática de Datos Abiertos Edafoclimáticos

Para complementar el conjunto de datos básico y PRO, se identifican las fuentes públicas que aportan variables determinantes del rendimiento del cereal:

Plataforma / Base de Datos	Entidad Emisora	Resolución Espacial y Temporal	Variables Clave Extraídas	Formato de Salida	Mecanismo de Consulta y Extracción
SoilGrids v2.0	ISRIC – World Soil Information	250 m / Estático	Contenido de arcilla, arena, limo, SOC, pH (H_2O), densidad aparente	GeoTIFF / JSON estructurado	API REST (https://rest.isric.org/soilgrids/v2.0/properties/query) y OGC WCS con Python

			(bdod), capacidad de campo (wv0033), PMP (wv1500) en intervalos: 0-5, 5-15, 15-30 y 30-60 cm		(owslib.wcs)[5]
OpenLandMap	EnvirometriX / OpenGeoHub	250 m – 1 km / Estático	Clases texturales USDA, profundidad a la roca dura, reservas de carbono orgánico a 30 cm	GeoTIFF / Cloud-Optimized GeoTIFF (COG)	Protocolo WCS o descarga vía GEE (ee.Image("OpenLandMap/..."))[28]
Cartografía Edafológica Serie II y IV	INEGI	Escala 1:250,000 / Levantamiento cartográfico	Tipo de suelo WRB, fase física superficial (lítica, pedregosa, tepetate), textura superficial	Vectorial Shapefile (SHP / Geopackage)	Portal de descargas temáticas de INEGI (https://www.inegi.org.mx/temas/edafologia/) o geoportal CONABIO[7]
NASA POWER Agroclimatology	NASA Langley Research Center	0.5° × 0.5° (~50 km) / Diario (latencia 1 a 2 días)	Radiación solar incidente en superficie (ALLSKY_SFC_SW_DWN	JSON estructurado / Tabular CSV	API REST (https://power.larc.nasa.gov/api/temporal/daily/point) o paquete

			), VPD, humedad relativa (RH2M), ET_0, $T_{\max}$, $T_{\min}$, precipitación corregida		Python nasapower
ERA5-Land	ECMWF / Copernicus CDS	0.1° (~9 km) / Horario y acumulado diario	Humedad volumétrica del suelo en 4 capas (0-7, 7-28, 28-100, 100-289 cm), evaporación potencial de la vegetación, temperatura superficial de suelo	NetCDF-4 / GRIB	API CDS de Copernicus vía cliente Python cdsapi (cds.climate.copernicus.eu)[6]
Estaciones Automáticas EMA	CONAGUA / SMN	Muestreo puntual / Intervalo horario a diario	Precipitación diaria puntual, temperatura horaria, vientos máximos, humedad de superficie	Formato tabular web / Archivo CSV	Portal interactivo de estaciones meteorológicas del SMN (smn.conagua.gob.mx)
Estadísticas Agrícolas	SADER / SIAP	Nivel municipal /	Superficie sembrada,	CSV / Base de datos	Módulo de descargas

SIAP		Anual (2018 – 2024)	cosechada, volumen de producción, rendimiento medio municipal (t/ha) diferenciado en temporal y riego	relacional SIACON	abiertas SIAP (gob.mx/siap)[8]

Protocolo de Automatización de Edafología con la API de SoilGrids v2.0

Para integrar las propiedades físicas e hidrológicas del suelo en cada parcela a partir de sus coordenadas centroidales, se ejecuta una consulta parametrizada a la API de ISRIC, escalando los coeficientes de acuerdo con la norma técnica de SoilGrids[5]:

```
Python
import requests
import pandas as pd

def consultar_propiedades_suelo(lat: float, lon: float) -> dict:
    url = "https://rest.isric.org/soilgrids/v2.0/properties/query"
    propiedades = ["clay", "sand", "silt", "soc", "phh2o", "bdod",
"wv0033", "wv1500"]
    profundidades = ["0-5cm", "5-15cm", "15-30cm", "30-60cm"]

    parametros = {
        "lon": lon,
        "lat": lat,
        "property": propiedades,
        "depth": profundidades,
        "value": "mean"
    }

    headers = {"Accept": "application/json"}
    respuesta = requests.get(url, params=parametros,
headers=headers, timeout=30)

    if respuesta.status_code != 200:
```

```
        raise RuntimeError(f"Error SoilGrids ({respuesta.status_code}):
{respuesta.text}")

    contenido = respuesta.json()
    registros = {}

    factores_escala = {
        "clay": 0.1,    # g/kg -> %
        "sand": 0.1,    # g/kg -> %
        "silt": 0.1,    # g/kg -> %
        "soc": 0.1,     # dg/kg -> g/kg
        "phh2o": 0.1,   # pH x 10 -> unidades de pH
        "bdod": 0.01,   # cg/cm³ -> kg/dm³ (g/cm³)
        "wv0033": 0.1,  # 10 x cm³/100cm³ -> % vol (Capacidad de Campo)
        "wv1500": 0.1   # 10 x cm³/100cm³ -> % vol (Punto de Marchitez
Permanente)
    }

    for capa in contenido["properties"]["layers"]:
        nombre_prop = capa["name"]
        factor = factores_escala.get(nombre_prop, 1.0)
        for subcapa in capa["depths"]:
            etiqueta = subcapa["label"]
            valor = subcapa["values"]["mean"]
            clave = f"{nombre_prop}_{etiqueta}"
            registros[clave] = (valor * factor) if valor is not None
else None

    # Estimación de la Capacidad de Agua Disponible (AWC = CC - PMP) en
el estrato superficial (0-30 cm)
    try:
        cc_ponderada = (registros["wv0033_0-5cm"] +
registros["wv0033_5-15cm"] + registros["wv0033_15-30cm"]) / 3.0
        pmp_ponderado = (registros["wv1500_0-5cm"] +
registros["wv1500_5-15cm"] + registros["wv1500_15-30cm"]) / 3.0
        registros["AWC_0_30cm_pct"] = max(0.0, cc_ponderada -
pmp_ponderado)
    except (TypeError, KeyError):
        registros["AWC_0_30cm_pct"] = None

    return registros
```

Para la cartografía de INEGI, se realiza una unión espacial (*spatial join*) con las capas vectoriales

Serie II/IV escala 1:250,000 correspondientes a las cartas E14-2 (Ciudad de México), E14-3 (Puebla) y F14-11 (Pachuca)[7]. De esta cartografía se extraen atributos determinantes: unidad WRB primaria (CLAVE_WRB), presencia de limitante física subsuperficial (FRUDICA, específicamente identificando fases de duripán/tepetate) y la clase textural declarada (CLASE_TEXT)[7].

Protocolo de Automatización Agrometeorológica con NASA POWER API

La extracción de datos diarios de radiación fotosintéticamente activa, déficit de presión de vapor y dinámica térmica se automatiza de la siguiente manera:

```
Python
import requests
import pandas as pd

def descargar_series_nasa_power(lat: float, lon: float, fecha_inicio: str
= "20250401", fecha_fin: str = "20251031") -> pd.DataFrame:
    endpoint = "https://power.larc.nasa.gov/api/temporal/daily/point"
    variables = [
        "ALLSKY_SFC_SW_DWN",  # Radiación solar incidente global de onda
corta (MJ/m²/día)
        "T2M_MAX",             # Temperatura máxima diaria a 2 m (°C)
        "T2M_MIN",             # Temperatura mínima diaria a 2 m (°C)
        "T2M",                 # Temperatura media a 2 m (°C)
        "VPD",                 # Déficit de presión de vapor atmosférico
(kPa)
        "RH2M",                # Humedad relativa media a 2 m (%)
        "PRECTOTCORR"          # Precipitación acumulada corregida
(mm/día)
    ]

    parametros = {
        "parameters": ",".join(variables),
        "community": "AG",
        "longitude": lon,
        "latitude": lat,
        "start": fecha_inicio,
        "end": fecha_fin,
        "format": "JSON"
    }

    respuesta = requests.get(endpoint, params=parametros,
timeout=40)
```

```
    if respuesta.status_code != 200:
        raise RuntimeError(f"Error NASA POWER API
({respuesta.status_code}): {respuesta.text}")

    cuerpo = respuesta.json()["properties"]["parameter"]
    df = pd.DataFrame(cuerpo)
    df.index = pd.to_datetime(df.index, format="%Y%m%d")
    df.index.name = "fecha"

    # Tratamiento de valores centinela del sistema (-999.0)
    df = df.replace(-999.0, float("nan")).interpolate(method="time")

    # Cálculo diario de GDD (Base 0 °C, Corte Superior 32 °C)
    tmax_filtrada = df["T2M_MAX"].clip(lower=0.0, upper=32.0)
    tmin_filtrada = df["T2M_MIN"].clip(lower=0.0, upper=32.0)
    df["GDD_diario"] = ((tmax_filtrada + tmin_filtrada) /
2.0).clip(lower=0.0)

    return df
```

Estaciones Meteorológicas Automáticas del SMN y Priors Agronómicos del SIAP

Para calibrar y validar las grillas climáticas de baja resolución espacial frente a registros instrumentales in situ, se ubican las estaciones meteorológicas automáticas (EMA) operadas por la CONAGUA dentro del radio de influencia de las parcelas[32]:

- **Estación ITESA-Apan (Hidalgo)**: Latitud 19.7180° N, Longitud -98.4663° O, Altitud 2,486 m s.n.m.[33].
- **Estación Calpulalpan (Tlaxcala)**: Latitud 19.5878° N, Longitud -98.5714° O, Altitud 2,560 m s.n.m.
- **Estación Tulancingo (Hidalgo)**: Latitud 20.0825° N, Longitud -98.3614° O, Altitud 2,165 m s.n.m.[34].
- **Estación Chignahuapan (Puebla)**: Latitud 19.8372° N, Longitud -98.0319° O, Altitud 2,260 m s.n.m.[32].

Por su parte, los registros históricos municipales del SIAP para cebada de temporal (2018–2024) proporcionan cotas empíricas que actúan como restricciones de plausibilidad física (*priors*) en el modelo[8]:

- **Chignahuapan (Puebla)**: Rendimiento medio de 4.10 a 4.65 t/ha (límite inferior: 2.20 t/ha, límite superior: 5.60 t/ha);
- **Llanos de Apan / Singuilucan (Hidalgo)**: Rendimiento medio de 3.30 a 3.90 t/ha (rango observado: 1.80 a 4.90 t/ha);
- **Calpulalpan / Nanacamilpa (Tlaxcala)**: Rendimiento medio de 2.65 a 3.25 t/ha (rango observado: 1.50 a 3.70 t/ha)[3].

Cualquier predicción en el conjunto de prueba que se desvíe en más de 2.5σ de estas distribuciones empíricas debe ser penalizada o revisada en el esquema de ensamblado.

Procesamiento de Series Temporales Satelitales, Mitigación de Nubosidad y Fusión Multisenso

La presencia recurrente de nubosidad durante la temporada húmeda estival induce caídas abruptas y artificiales en los índices de vegetación ópticos[35]. El tratamiento de estos vacíos y observaciones degradadas requiere métodos matemáticos de reconstrucción temporal que garanticen la fidelidad biofísica del perfil fenológico.

Algoritmos de Filtrado y Reconstrucción Temporal de Señales

Para restaurar las series temporales de índices espectrales (NDVI, EVI, LAI, NDWI), se analizan los métodos de suavizado y ajuste de curvas más eficaces:

Algoritmo	Mecanismo Matemático	Manejo de Nubosidad y QA	Ventajas Operativas	Desventajas o Limitaciones
Whittaker-Eilers	Ajuste por mínimos cuadrados penalizado por regularización de diferencias finitas[36]	Nativo: asigna pesos $w_i \in$ basados en la calidad radiométrica y nubosidad[35]	Equilibrio configurable entre fidelidad y suavidad (λ); resuelve perfiles asimétricos con baches prolongados[36]	Requiere optimización del parámetro de penalización (λ) por validación cruzada
Doble Logístico *(Beck et al., 2006)*	Ajuste de una función no lineal de 6 parámetros que modela crecimiento y senescencia[37]	Indirecto: las observaciones degradadas deben ser enmascaradas o eliminadas a priori	Excelente estabilidad funcional ante lagunas de datos largas durante el pico del cultivo[40]	Rigidez paramétrica; no captura perturbaciones por eventos extremos o crecimiento intraestival
Savitzky-Golay	Convolución local adaptativa	Requiere filtrado previo de nubes e	Preserva con fidelidad los picos locales	Muy sensible a secuencias consecutivas

	mediante ajuste por regresión polinomial móvil[42]	interpolación previa sobre cuadrículas temporales uniformes	angostos cuando los datos están limpios	de nubes densas; induce artefactos oscilatorios[36]

El algoritmo de Whittaker-Eilers se establece como el estándar metodológico preferente para el reto[13]. Minimiza formalmente la función de pérdida penalizada Q:

$$Q = \sum_{i=1}^{m} w_i (y_i - z_i)^2 + \lambda \sum_{i=1}^{m-d} (\Delta^d z_i)^2$$

donde y_i corresponde a las observaciones espectrales registradas, z_i es el vector ajustado suave, d es el orden de las diferencias finitas (se adopta $d = 2$ para penalizar segundas derivadas excesivas), λ es el coeficiente de rugosidad, y w_i denota el vector de pesos de calidad atmosférica[36]. Dicho vector se parametriza a partir de la máscara de calidad QA:

- $w_i = 1.0$ para observaciones con cielo completamente despejado (porcentaje_nubosidad = 0);
- $w_i = 0.2$ para observaciones con aerosoles altos o nubes cirro difusas;
- $w_i = 0.0$ para observaciones contaminadas por nubes densas o sombras proyectadas (porcentaje_nubosidad > 20%), lo que fuerza al algoritmo a interpolar dinámicamente el valor faltante a partir de las observaciones circundantes limpias[35].

En forma matricial compacta, la solución analítica se obtiene resolviendo el sistema lineal simétrico de bandas:

$$(W + \lambda D_d^T D_d)\mathbf{z} = W\mathbf{y}$$

donde $W = \mathrm{diag}(w_1, \ldots, w_m)$ y D_d es la matriz diferencial de orden d [36]. En Python, este proceso se ejecuta mediante la librería whittaker-eilers sobre las series temporales de cada parcela[35].

Para modelado paramétrico complementario, la formulación doble logística de Beck et al. (2006) describe la evolución temporal del índice $f(t)$ [37]:

$$f(t) = \alpha_1 + (\alpha_2 - \alpha_1)\left(\frac{1}{1+\exp\left(-\beta_1(t-\tau_1)\right)} + \frac{1}{1+\exp\left(-\beta_2(t-\tau_2)\right)} - 1\right)$$

donde α_1 denota la reflectancia basal de suelo o residuo vegetal, α_2 es la amplitud máxima alcanzada, β_1 y β_2 gobiernan las tasas normalizadas de emergencia y senescencia, y τ_1 y τ_2 sitúan cronológicamente los puntos de inflexión temporal de inicio y declive del dosel[37].

Extracción de Rasgos Fenológicos Cuantitativos (*Pheno-Metrics*)

A partir de las trayectorias temporales reconstruidas de los índices NDVI, EVI, NDWI y LAI, se derivan métricas fenológicas cuantitativas con probada sensibilidad biofísica frente al rendimiento de grano[42]:

Métrica Fenológica	Definición Analítica	Relevancia Agronómica y Fisiológica
Inicio de Estación (SOS)	Día del año (DOY) donde la curva supera el 20% de su amplitud estacional ascendente[42]	Identifica la fecha efectiva de emergencia del cultivo y el vigor inicial de establecimiento[37]
Fecha del Pico (POS)	DOY en el cual la curva de vegetación alcanza su valor máximo absoluto ($z_{\max}$)[43]	Sincronía fenológica con la antesis; fecha de máxima biomasa fotosintéticamente activa[42]
Valor del Pico (vPOS)	Amplitud máxima alcanzada por el índice en la temporada ($z(POS)$)[43]	Indicador del índice de área foliar máximo (LAI) y de la capacidad fotosintética potencial[44]
Fin de Estación (EOS)	DOY donde la curva desciende al 20% de la amplitud estacional en la fase de senescencia[42]	Maduración fisiológica del grano y secado del dosel vegetal[37]
Longitud de Estación (LOS)	Duración temporal activa del dosel: $\mathrm{LOS} = \mathrm{EOS} -$	Tiempo total de intercepción de radiación durante el ciclo agrícola

	[cite: 37, 43]	
Área Bajo la Curva en Llenado (AUC_Llenado)	Integral temporal del índice desde la fecha del pico hasta el fin de la estación: $\int_{\mathrm{POS}}^{\mathrm{EOS}} z(t)\, dt$	Métrica con máxima correlación con el rendimiento; captura el efecto *stay-green* y la síntesis de almidón[2]
Tasa de Senescencia	Pendiente media de declive del índice: $\frac{z(\mathrm{POS}) - z(\mathrm{EOS})}{\mathrm{EOS} - \mathrm{POS}}$ [cite: 43]	Permite detectar estrés terminal por desecación violenta o forzado térmico del llenado
Amplitud Estacional	Amplitud dinámica: $z(\mathrm{POS}) -$ [cite: 37, 43]	Magnitud del desarrollo vegetativo neta sobre el fondo espectral del suelo

En la literatura de teledetección aplicada a cereales de grano pequeño, la integral temporal de llenado de grano (AUC_Llenado) y el valor máximo del pico (vPOS) explican de manera consistente más del 65% de la varianza del rendimiento de grano ($R^2 > 0.65$), puesto que integran la duración del área foliar activa durante la fase de translocación hacia el grano[2].

Estrategia de Armonización y Fusión Espectral Multisenso

La presencia conjunta de observaciones de Sentinel-2 (10–20 m), Landsat 8/9 (30 m) y PlanetScope (~3 m) requiere una estrategia de integración que prevenga distorsiones radiométricas[45]:

Sensor	Resolución Espacial	Bandas Clave	Ancho de Banda Rojo (nm)	Ancho de Banda NIR (nm)	Enfoque de Integración Recomendado
Sentinel-2 MSI	10 m / 20 m	B2, B3, B4, B8, B8A, B11, B12	650 – 680 (B4)	785 – 900 (B8), 855 – 875 (B8A)	Sensor de referencia primaria; preserva bandas de borde rojo (*Red-Edge*) [44]

Landsat 8/9 OLI	30 m	B2, B3, B4, B5, B6, B7	636 – 673 (B4)	851 – 879 (B5)	Homogeneización espectral mediante transformación lineal HLS hacia bandas MSI[45]
PlanetScope	~3 m	Azul, Verde, Rojo, NIR (4/8 bandas)	590 – 670	780 – 860	Rama analítica independiente para métricas fenológicas de alta frecuencia y textura intra-parcelaria[44]

Se establecen tres directrices operativas de fusión:

1. **Armonización Espectral Sentinel-2 y Landsat**: Se aplican los coeficientes de ajuste espectral de banda (*bandpass adjustment*) desarrollados en la iniciativa HLS de la NASA/USGS[45]. Para proyectar la reflectancia de Sentinel-2 hacia la escala de Landsat OLI se emplea:

$$\rho_{\text{OLI}} = a \cdot \rho_{\text{MSI}} + b$$

utilizando los coeficientes oficiales para el espectro visible e infrarrojo cercano: $a_{\text{Red}} = 1.017$, $b_{\text{Red}} = -0.00104$; y para el NIR estrecho (B8A de MSI a B5 de OLI): $a_{\text{NIR}} = 0.999$, $b_{\text{NIR}} = 0.00025$ [47]. Con ello, ambas series pueden combinarse en una única trayectoria temporal de 30 m sin sesgos instrumentales[45]. 2. **Aislamiento de la Constelación PlanetScope**: Dadas las variaciones en la calibración cruzada entre los microsatélites CubeSat de PlanetScope, no se deben mezclar valores puntuales de reflectancia cruda con los de Sentinel-2[44]. La constelación Planet debe procesarse como una rama de soporte temporal dedicada a determinar la fecha exacta de antesis (POS) y la heterogeneidad espacial intra-parcelaria (cuantificada como la varianza zonal de NDVI en el pico del cultivo, _std)[44]. 3. **Normalización por Puntuación Z por Sensor**: En caso de requerir la

combinación multisenso de un índice específico en fechas solapadas, se calcula el índice z-score normalizado a nivel regional para cada sensor s en la fecha t:

$$z_{i,t} = \frac{\mathrm{VI}_{i,t,s} - \mu_{t,s}}{\sigma_{t,s}}$$

neutralizando posibles derivas de ganancia atmosférica o calibración radiométrica entre plataformas.

Arquitectura de Aprendizaje Automático Geoespacial, Regularización y Validación Espacial

El modelado predictivo debe resolver de forma rigurosa la colinealidad y la asimetría dimensional entre el número de parcelas de entrenamiento ($N = 138$) y los cientos de atributos derivados de sensores remotos, capas pedológicas y datos climáticos ($p \gg N$)[44].

Reducción Dimensional Supervisada en Regímenes de Pocas Muestras

La selección de características se estructura en un procedimiento en dos etapas concebido para retener exclusivamente las variables biofísicamente informativas:

Etapa del Pipeline	Método Aplicado	Criterio de Selección	Dimensión de Entrada	Dimensión Resultante
Filtro de Descorrelación	mRMR (*Minimum Redundancy Maximum Relevance*)	Maximización de la información mutua con el rendimiento y penalización por correlación de Pearson inter-variable ($\lvert r \rvert >$)[10]	$p >$ características totales	$p \approx$ características no redundantes
Confirmación Biofísica	Boruta-SHAP sobre ensamble de árboles	Comparación estadística del impacto SHAP contra variables artificiales	$p \approx$ características filtradas	$p \approx 12 -$ predictores confirmados

		aleatorias (*shadow features*)[9]		

El algoritmo Boruta-SHAP genera réplicas aleatorias permutadas de cada covariable real. En cada iteración de un bosque de decisión, se calcula el valor absoluto medio de atribución SHAP para todas las variables[9]. Una característica real solo es aceptada si su contribución predictiva supera de forma estadísticamente significativa ($p < 0.01$, prueba de dos colas) al valor máximo registrado por cualquier variable sombra[9]. Esto descarta factores espurios que aparentan predictibilidad por simple memorización de ruido local.

Validación Cruzada Espacialmente Bloqueada y Fuga de Datos Geográfica

El uso de validación cruzada aleatoria convencional (K-Fold aleatorio) es metodológicamente inválido en datos geoespaciales[11]. Debido a la autocorrelación espacial descrita por Tobler (parcelas cercanas comparten climas, tipos de suelo y regímenes de manejo similares), una partición aleatoria genera una severa fuga de datos (*spatial data leakage*)[12]. Los modelos sobreajustados obtienen valores optimistas ficticios de $R^2 > 0.85$ en validación interna, para luego colapsar catastróficamente al predecir parcelas en zonas geográficas no observadas[11].

Para garantizar que el error estimado refleje la verdadera capacidad de generalización sobre las 59 parcelas de prueba, se implementa una partición espacial en bloques[11]:

Bloque de Validación	Ámbito Geográfico Evaluado	Parcelas de Calibración (Train)	Justificación Agronómica y Espacial
Fold 1	Chignahuapan Norte (Puebla)	Parcelas de Chignahuapan Sur, todo Hidalgo y todo Tlaxcala	Evalúa la capacidad de transferibilidad dentro de la zona de alta productividad de Andosoles
Fold 2	Chignahuapan Sur (Puebla)	Parcelas de Chignahuapan Norte, todo Hidalgo y todo Tlaxcala	Previene la memorización de factores microclimáticos propios de la Sierra

			de Puebla
Fold 3	Llanos de Apan / Tepeapulco (Hidalgo)	Todas las parcelas de Puebla, Tlaxcala y municipios restantes de Hidalgo	Prueba la inferencia en zonas semiáridas con canícula acentuada
Fold 4	Singuilucan / Cuautepec / Almoloya (Hidalgo)	Todas las parcelas de Puebla, Tlaxcala y Llanos de Apan	Valida la predicción en suelos de transición Cambisol-Phaeozem
Fold 5	Calpulalpan / Nanacamilpa (Tlaxcala)	Todas las parcelas de Puebla y todas las parcelas de Hidalgo	Prueba estricta de extrapolación hacia zonas limitadas por tepetates someros y estrés severo[3]

Se utiliza la clase GroupKFold de scikit-learn agrupando por municipio, complementada con un búfer de exclusión espacial de 3.5 km para evitar que parcelas del entrenamiento situadas en el límite municipal contaminen el pliegue de prueba[11].

Evaluación Comparativa de Familias Algorítmicas ($N = 138$)

Dadas las dimensiones del dataset de calibración, se descarta el empleo de redes neuronales profundas y se contrastan modelos con control analítico del balance sesgo-varianza:

Familia de Modelos	Algoritmo Evaluado	Idoneidad para N=138	Ventajas Analíticas	Riesgos Específicos y Medidas de Control
Lineales Regularizados	**ElasticNet / Bayesian Ridge**	Muy Alta	Coeficientes explicables; penalización combinada L_1 y L_2; imposible de sobreajustar	Asume relaciones lineales; requiere ingeniería previa de no linealidades y ratios

			con hiperparámetros óptimos	biofísicos
Procesos Gaussianos	**Gaussian Process Regression (GPR)**	Muy Alta	Formulación no paramétrica óptima para $N <$; provee cuantificación probabilística de incertidumbre (σ^2) en cada estimación	Sensible al ruido de covariables irrelevantes; mitigado con kernels ARD (*Automatic Relevance Determination*) [13]
Vectores de Soporte	**Support Vector Regression (SVR)**	Alta	Eficiente en dimensiones moderadas con kernel RBF; robusto ante valores atípicos mediante margen ϵ -insensible	Sensible a la escala de las variables; calibración crítica de los parámetros C , ϵ y γ
Potenciación de Gradiente	**CatBoost / LightGBM**	Moderada a Alta	Modela interacciones biofísicas no lineales complejas y umbrales de choque térmico	Propensión a memorizar muestras en $N =$; requiere limitar max_depth a $\leq$, regularización $L_2 \geq$ y submuestreo

Ensamble por Apilamiento	**Stacking Regressor**	Muy Alta *(Estrategia Seleccionada)*	Sinergia funcional: balancea la solidez de ElasticNet, la modelación de incertidumbre de GPR y la no linealidad de CatBoost	El meta-estimador debe ser estrictamente lineal (Ridge) sobre predicciones *out-of-fold*

La función de costo del estimador ElasticNet minimiza la norma penalizada:

$$\min_{\mathbf{w}} \frac{1}{2N}\|\mathbf{y} - X\mathbf{w}\|_2^2 + \alpha\rho\|\mathbf{w}\|_1 + \frac{\alpha(1-\rho)}{2}\|\mathbf{w}\|_2^2$$

donde α determina la intensidad global de la penalización y $\rho \in [0,1]$ equilibra la inducción de dispersión tipo Lasso ($\rho = 1$) y el encogimiento de coeficientes colineales tipo Ridge ($\rho = 0$).

Para el proceso gaussiano (GPR), se especifica un kernel de covarianza de determinación automática de relevancia (ARD) sumado a un término de ruido gaussiano blanco[13]:

$$k(\mathbf{x}_i, \mathbf{x}_j) = \sigma_f^2 \exp\left(-\frac{1}{2}\sum_{k=1}^{p}\frac{(x_{i,k} - x_{j,k})^2}{\ell_k^2}\right) + \sigma_n^2\delta_{ij}$$

donde ℓ_k es la escala de longitud asignada a la característica k[13]. Si una variable carece de valor predictivo, el proceso de optimización por máxima verosimilitud marginal incrementa $\ell_k \to \infty$, suprimiendo su influencia en la covarianza[13].

El ensamble final por apilamiento entrena en paralelo tres estimadores base: ElasticNetCV, GaussianProcessRegressor (con kernel ARD) y CatBoostRegressor (con hiperparámetros restringidos: depth=3, l2_leaf_reg=6.0, learning_rate=0.03). Las predicciones fuera de pliegue (*out-of-fold*) se integran mediante un meta-estimador lineal RidgeCV no negativo, garantizando una ponderación biológicamente estable.

Métricas Cuantitativas de Desempeño y Validación

La evaluación del poder predictivo se realiza a través de cuatro métricas complementarias:

$$\text{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}$$

El Error Cuadrático Medio penaliza cuadráticamente los errores de gran magnitud, asegurando que el modelo evite desviaciones extremas en parcelas puntuales.

$$\text{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

El Error Absoluto Medio cuantifica la incertidumbre media esperada en unidades agronómicas reales (t/ha), facilitando la interpretación técnica de los resultados.

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}$$

El Coeficiente de Determinación evalúa la proporción de varianza del rendimiento capturada por el modelo en comparación con una predicción ingenua basada en la media muestral.

$$\text{MAPE} = \frac{100\%}{N}\sum_{i=1}^{N}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

El Error Porcentual Absoluto Medio evalúa el error relativo respecto a la escala de rendimiento de cada parcela, permitiendo comprobar que la precisión sea equilibrada tanto en parcelas de bajo rendimiento (Tlaxcala: ~2.5 t/ha) como en parcelas de alto rendimiento (Puebla: ~5.0 t/ha).

Explicabilidad Agronómica con SHAP (SHapley Additive exPlanations)

Para certificar que el modelo aprenda procesos agrobiológicos válidos y no correlaciones espurias, se audita el ensamble mediante valores SHAP basados en teoría de juegos[9]. La predicción para una parcela individual $\hat{y}_i$ se descompone en la suma de su valor base esperado más las contribuciones marginales locales de cada predictor ϕ_j:

$$\hat{y}_i = \phi_0 + \sum_{j=1}^{p}\phi_j(x_{i,j})$$

Los criterios para validar la consistencia física del modelo son:

- **Respuesta de la Integral de Llenado (AUC_Llenado)**: Debe mostrar una relación monótona positiva uniforme con el rendimiento; valores altos de absorción fotosintética

acumulada pos-antesis deben reflejar valores de Shapley consistentemente positivos ($\phi > 0$)[2].

- **Sensibilidad al Estrés por Déficit de Presión de Vapor (VPD_julio_agosto)**: Debe manifestar un comportamiento de umbral; cuando el VPD excede 1.8 kPa durante las horas centrales del día en floración, las atribuciones de Shapley deben contraerse drásticamente al rango negativo ($\phi < -0.3 \text{ t/ha}$) debido a la pérdida de biomasa por fotorrespiración y cierre estomático[4].
- **Respuesta Edáfica (AWC_0_30cm y SOC)**: La capacidad de retención de agua y el contenido de carbono orgánico deben presentar contribuciones marginales positivas en las subregiones secas de Hidalgo y Tlaxcala, demostrando que el modelo reconoce el efecto amortiguador del suelo ante eventos caniculares[5].
- **Control de Coordenadas Geográficas puras**: Si se verifica que las coordenadas de longitud y latitud acaparan los mayores valores absolutos de SHAP desplazando a los rasgos funcionales de satélite y clima, el modelo habrá memorizado la geografía comarcal en lugar de aprender los mecanismos biofísicos del cultivo[12]. Ante tal escenario, se ordena la eliminación inmediata de las coordenadas explícitas de la matriz de entrenamiento para restaurar la generalizabilidad del sistema[12].

La consolidación de un flujo que combina el conocimiento ecofisiológico de la cebada maltera, el filtrado de interferencias atmosféricas mediante el suavizado de Whittaker-Eilers, la integración de capas edafoclimáticas abiertas de alta resolución y un esquema estricto de validación cruzada espacial bloqueada permite mitigar los riesgos derivados del sobreajuste en el régimen $p \gg N$, suministrando predicciones de rendimiento para el Reto AgroCebada 2026 que son estadísticamente precisas, biológicamente congruentes y generalizables entre las distintas regiones productivas del Altiplano Central mexicano.

Fuentes citadas

1. Cebada maltera de temporal en Valles Altos de México - Gob MX, https://www.gob.mx/inifap/articulos/cebada-maltera-de-temporal-en-valles-altos-de-mexico
2. Manejo agronómico de cebada maltera. Rendimiento de semilla, https://www.somecta.org.mx/Revistas/somectavol.2.1/4.%20CYTAM-2014-07.%20JOSEA.RANGELLUCIO.pdf
3. IMPACTO EN LA PRODUCCIÓN DE CEBADA (Hordeum vulgare, https://www.redalyc.org/pdf/461/46142593002.pdf
4. Sequía se triplica en Puebla: pasa de 35 a 105 municipios, https://oem.com.mx/elsoldepuebla/local/sequia-se-triplica-en-puebla-pasa-de-35-a-105-municipios-afectados-en-un-ano-32086949
5. Get SoilGrids 2.0 Property Estimates for Points or Spatial Extent, https://ncss-tech.github.io/soilDB/reference/fetchSoilGrids.html
6. Pasture Biomass Monitoring in Queensland Rangelands with UAV,

https://www.mdpi.com/2624-7402/8/8/317
7. Conjunto de datos vectoriales edafológico, escala 1:250000 Serie II, http://geoportal.conabio.gob.mx/metadatos/doc/html/eda250s2gw.html
8. RD-1327.3.pdf, http://repositorio.imta.mx/bitstream/handle/20.500.12013/1895/RD-1327.3.pdf?sequence=1&isAllowed=y
9. GitHub - Ekeany/Boruta-Shap: A Tree based feature selection tool, https://github.com/Ekeany/Boruta-Shap
10. mrmr-selection - PyPI, https://pypi.org/project/mrmr-selection/
11. (PDF) Spatial cross-validation is not the right way to evaluate map, https://www.researchgate.net/publication/353729299_Spatial_cross-validation_is_not_the_right_way_to_evaluate_map_accuracy
12. Adapting machine learning for environmental spatial data -A review, https://www.researchgate.net/publication/381553619_Adapting_machine_learning_for_environmental_spatial_data_-A_review
13. Quantifying Irrigated Winter Wheat LAI in Argentina Using Multiple, https://www.mdpi.com/2072-4292/14/22/5867
14. Feature Selection by Boruta-SHAP for Ubiquant - Kaggle, https://www.kaggle.com/code/lucamassaron/feature-selection-by-boruta-shap-for-ubiquant
15. Adabella: variedad de cebada maltera para valles altos de la mesa, https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0568-25172008000400012
16. Variedades de cebada recomendadas por el INIFAP - Gob MX, https://www.gob.mx/inifap/articulos/materiales-de-cebada-recomendados-por-el-inifap
17. rendimiento de grano y características fisicoquímicas de cebada en, https://revfitotecnia.mx/index.php/RFM/article/download/2052/1950/3025
18. MANUAL DE TRIGO Y CEBADA PARA EL CONO SUR PROCESOS, https://aws.agroconsultasonline.com/ticket.html/Miralles%20-%20Manual%20de%20Trigo%20-%20press.pdf?op=d&ticket_id=9972&evento_id=20750
19. Decision Support for Crop Management Using Remote Sensing, https://elibrary.asabe.org/azdez.asp?JID=1&AID=8350&CID=cia2002&T=1
20. Regional Yield Predictions of Malting Barley by Remote Sensing, https://www.researchgate.net/publication/252909886_Regional_Yield_Predictions_of_Malting_Barley_by_Remote_Sensing_and_Ancillary_Data
21. Rendimiento de grano y características fisicoquímicas de cebada en, https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0187-73802025000300285
22. Guía rápida para el cultivo de cebada - Agroptima, https://blog.agroptima.com/es/blog/guia-rapida-para-el-cultivo-de-cebada/
23. Del 01 al 15 de mayo de 2025 - Gobierno del Estado de Puebla, https://smadsot.puebla.gob.mx/images/Cambio-climatico/anteriores/Reporte_Quincenal_SMADSOT_150525.pdf
24. Junio de 2025, el más lluvioso desde 1941; sequía retrocede en,

https://www.porcicultura.com/noticias/junio-de-2025-el-mas-lluvioso-desde-1941-sequia-retrocede-en-mexico
25. Tlaxcala registra 11.8% menos lluvia que en 2025; solo dos, https://www.periodicoenfoque.com.mx/tlaxcala/tlaxcala-registra-11-8-menos-lluvia-que-en-2025-solo-dos-regiones-aumentaron
26. WCS - SoilGrids Documentation - ISRIC - World Soil Information, https://docs.isric.org/globaldata/soilgrids/wcs.html
27. Access soilgrid data using the WCS protocol - Ecodiv.earth, https://ecodiv.earth/post/downloading-soilgrid-data/
28. A Collaborative Platform for Soil Organic Carbon Inference Based, https://www.researchgate.net/publication/390990308_A_Collaborative_Platform_for_Soil_Organic_Carbon_Inference_Based_on_Spatiotemporal_Remote_Sensing_Data
29. CIR-CENTRO - Gob MX, https://www.gob.mx/cms/uploads/attachment/file/836561/Formato_REPORTE_ANUAL_2022_EdoMex.pdf
30. Calidad y vigor en semilla de cebada cv . Brennus - ResearchGate, https://www.researchgate.net/publication/387116925_Calidad_y_vigor_en_semilla_de_cebada_cv_Brennus
31. Edafología - Geoportal CONABIO, http://geoportal.conabio.gob.mx/metadatos/doc/html/eda251mgw.html
32. ATLAS DE RIESGO EN EL MUNICIPIO DE SAN ANDRÉS CHOLULA, http://rmgir.proyectomesoamerica.org/PDFMunicipales/2011/vr_21119_AR_San_Andres_Cholula.pdf
33. T E S I N A - ptolomeo.unam.mx, http://www.ptolomeo.unam.mx:8080/xmlui/bitstream/handle/132.248.52.100/16346/Tesina%20para%20CD.pdf?sequence=1&isAllowed=y
34. Atlas de Riesgos y/o Peligros del municipio de Santiago Tulantepec, http://rmgir.proyectomesoamerica.org/AtlasMunPDF/2023/13056_SANTIAGO_TULANTEPEC_2023.pdf
35. Seeing Through the Clouds: How We Make Satellite Crop ... - My Store, https://www.aboutiiot.com/blogs/agriculture-monitoring/seeing-through-the-clouds-how-we-make-satellite-crop-monitoring-reliable-when-the-sky-isnt
36. A robust method for reconstructing global MODIS EVI time series on, https://www.researchgate.net/publication/334130788_A_robust_method_for_reconstructing_global_MODIS_EVI_time_series_on_the_Google_Earth_Engine
37. Spatiotemporal image fusion in Google Earth Engine for annual, https://www.researchgate.net/publication/350770184_Spatiotemporal_image_fusion_in_Google_Earth_Engine_for_annual_estimates_of_land_surface_phenology_in_a_heterogenous_landscape
38. FitDoubleLogBeck: Fit a double logisitic function to a vector ... - rdrr.io, https://rdrr.io/rforge/greenbrown/man/FitDoubleLogBeck.html
39. Weighted Double-Logistic Function Fitting Method for ... - MDPI, https://www.mdpi.com/2072-4292/11/20/2342
40. (PDF) A spatially explicit land surface phenology data product for,

https://www.researchgate.net/publication/269701213_A_spatially_explicit_land_surface_phenology_data_product_for_science_monitoring_and_natural_resources_management_applications
41. (PDF) Weighted Double-Logistic Function Fitting Method for, https://www.researchgate.net/publication/336403318_Weighted_Double-Logistic_Function_Fitting_Method_for_Reconstructing_the_High-Quality_Sentinel-2_NDVI_Time_Series_Data_Set
42. Towards Optimising the Derivation of Phenological Phases ... - MDPI, https://www.mdpi.com/2072-4292/16/17/3183
43. JavierLopatin/PhenoSensing: Phenological analysis of ... - GitHub, https://github.com/JavierLopatin/PhenoPY
44. Impact of spatial resolution on the quality of crop yield predictions for, https://www.researchgate.net/publication/354199088_Impact_of_spatial_resolution_on_the_quality_of_crop_yield_predictions_for_site-specific_crop_management
45. Harmonized Landsat Sentinel-2 (HLS) Product User Guide | LP DAAC, https://lpdaac.usgs.gov/documents/1007/HLS_User_Guide_V15_provisional.pdf
46. Harmonized Landsat Sentinel-2 (HLS) Product User Guide - LP DAAC, https://lpdaac.usgs.gov/documents/1698/HLS_User_Guide_V2.pdf
47. (PDF) Harmonized Landsat-8 Sentinel-2 (HLS) Product User's Guide, https://www.researchgate.net/publication/314154338_Harmonized_Landsat-8_Sentinel-2_HLS_Product_User's_Guide
48. Impact of Data Spatial Resolution on Barley Yield Prediction Mapping, https://www.researchgate.net/publication/394077719_Impact_of_Data_Spatial_Resolution_on_Barley_Yield_Prediction_Mapping
49. Selection of Independent Variables for Crop Yield Prediction Using, https://www.mdpi.com/2073-445X/10/6/609
50. MRMR — 1.8.3 - Feature-engine, https://feature-engine.trainindata.com/en/1.8.x/api_doc/selection/MRMR.html
51. Boruta-Shap/src/BorutaShap.py at master - GitHub, https://github.com/Ekeany/Boruta-Shap/blob/master/src/BorutaShap.py
52. Importance of spatial predictor variable selection in machine, https://www.researchgate.net/publication/335819474_Importance_of_spatial_predictor_variable_selection_in_machine_learning_applications_-Moving_from_data_reproduction_to_spatial_prediction