Reto AgroCebada 2026: reporte técnico.

1. Introducción.

La cebada maltera (Hordeum vulgare L.) constituye uno de los pilares agroindustriales y socioeconómicos más estratégicos del Altiplano Central Mexicano, con concentraciones productivas preponderantes en los valles altos de Hidalgo, Tlaxcala y Puebla, así como en áreas tecnificadas del Bajío en Guanajuato. A diferencia de los sistemas de regadío intensivo, la producción de cebada en estas regiones se desarrolla mayoritariamente bajo regímenes de temporal (rainfed), exponiendo a los cultivos a una severa vulnerabilidad frente a la variabilidad hidroclimática intra-estacional: sequías tempranas que comprometen la densidad de población, heladas radiativas durante la floración y ondas de calor que truncan el período crítico de llenado de grano.

En este contexto, la estimación anticipada y precisa del rendimiento de grano por hectárea (Y_i, expresado en t/ha) a escala de parcela agrícola individual representa un imperativo para la planificación logística y de abasto de la industria cervecera, así como para la mitigación de riesgos crediticios en el agro. No obstante, modelar el rendimiento a nivel parcelario entraña un desafío metodológico multidimensional. Formalmente, la respuesta agronómica de una parcela i puede conceptualizarse bajo la siguiente función generadora:

$$Y_i = f(X_i^{\text{espectral}}(t), Z_i^{\text{meteo}}(t), T_i^{\text{topo}}, s_i) + \eta_{r(i)} + \varepsilon_i$$

donde $X_i^{\text{espectral}}(t)$representa la trayectoria temporal multiespectral de reflectancia e índices de biomasa y agua foliar (Sentinel-2 y PlanetScope a 3 m); $Z_i^{\text{meteo}}(t)$ captura las covariables agroclimáticas diarias (temperaturas extremas, déficit de presión de vapor y balance hídrico) sincronizadas dinámicamente con las fases fenológicas del cultivo; T_i^{topo}describe la posición topográfica relativa e inclinación del terreno; $s_i = (\text{lat}_i, \text{lon}_i)$parametriza la dependencia espacial intrínseca; $\eta_{r(i)}$ modela el sesgo estructural inducido por el régimen de reporte (pesadas en báscula de comercializadora con precisión de dos decimales frente a declaraciones de productores sujetas a redondeo); y $\varepsilon_i \sim \mathcal{N}(0, \sigma_i^2)$ cuantifica el error aleatorio e instrumental irreducible.

El principal obstáculo en la literatura radica en que los algoritmos predictivos tradicionales suelen incurrir en severo sobreajuste o en una apreciación optimista espuria al ignorar la autocorrelación espacial y la naturaleza de datos tabulares reducidos ($N < 200$). Asimismo, el uso exclusivo de índices de vegetación integrados a nivel estacional tiende a enmascarar siniestros episódicos breves pero determinantes, tales como choques térmicos en antesis o humedecimiento tardío previo a la cosecha.

El presente trabajo aborda esta problemática mediante el diseño, formulación y validación empírica de una arquitectura predictiva bi-etapa con regularización espacial y encogimiento adaptativo (*Empirical Bayes*). Integrando firmas satelitales de ciclo completo, reanálisis meteorológico diario a mesoescala corregido por gradiente adiabático, kernels de contigüidad física entre linderos parcelarios e inferencia conformal para la cuantificación formal de incertidumbre, se demuestra cómo desacoplar el sesgo de reporte municipal y maximizar la precisión predictiva, asegurando estabilidad tanto en esquemas de muestreo estratificado como ante rigurosa extrapolación geográfica en el campo mexicano.

2. Justificación.

La asimetría de información en el sector agrícola tradicional genera distorsiones económicas severas: las instituciones financieras y aseguradoras perciben la producción de temporal como una actividad de alto riesgo e incuantificable, lo que deriva en primas crediticias prohibitivas, escasez de liquidez y liquidaciones tardías de coberturas. A su vez, la agroindustria maltera enfrenta incertidumbre logística y sobrecostos millonarios al depender de estimaciones retrospectivas o promedios municipales del SIAP que no reflejan la heterogeneidad productiva real entre parcelas vecinas.

Desarrollar un sistema predictivo capaz de anticipar el rendimiento de grano a escala de lote individual con base en física de sensores remotos, agroclimatología y aprendizaje estadístico riguroso resuelve este desfase estructural. Al sustituir la subjetividad de las declaraciones en campo por métricas satelitales auditables y proveer intervalos de incertidumbre calibrados formalmente mediante inferencia conformal, este desarrollo no solo optimiza la planificación del abasto industrial, sino que establece una base matemática confiable para estructurar pólizas de seguro paramétrico justas y dinamizar la inclusión financiera de pequeños y medianos productores en el Altiplano Central Mexicano.

3. Objetivos.

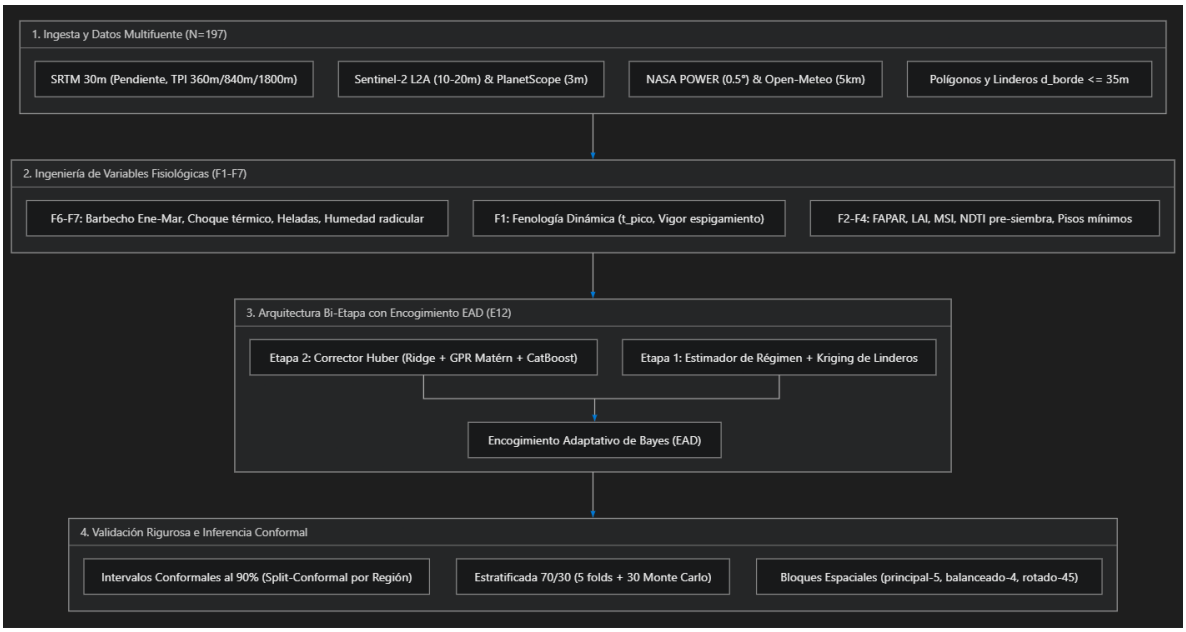
Objetivo General. Desarrollar, validar y desplegar un sistema predictivo de aprendizaje automático capaz de estimar el rendimiento de grano de cebada maltera (*Hordeum vulgare L.*) a escala de parcela individual en el Altiplano Central Mexicano, garantizando robustez ante la heterogeneidad regional y una cuantificación rigurosa de la incertidumbre.

Objetivos Específicos

1. **Ingeniería de variables agroclimáticas y satelitales:** Integrar series temporales multiespectrales de Sentinel-2 y PlanetScope (3 m) con reanálisis meteorológico diario (Open-Meteo y NASA POWER) y micro-topografía (TPI), sincronizados con las ventanas fenológicas críticas del cultivo.

2. **Modelado y desacoplamiento estructural:** Formular una arquitectura predictiva bi-etapa que desacople los regímenes de reporte municipal (comercializadora vs. productor), incorpore kernels de contigüidad entre linderos y aplique encogimiento adaptativo (*Empirical Bayes*).
3. **Validación espacial y reproductibilidad:** Evaluar los modelos bajo esquemas estrictos de validación cruzada estratificada y bloques espaciales independientes, erradicando cualquier fuga de información (*target leakage*).
4. **Calibración de incertidumbre operativa:** Implementar inferencia conformal adaptativa para generar intervalos de predicción al 90% de confianza que respalden la suscripción de riesgos y la planificación agroindustrial.

4. Metodología



4.1. Conjunto de Datos y Preprocesamiento Multifuente

El estudio comprende 197 polígonos parcelarios georreferenciados en el Altiplano Central y Bajío mexicano (138 de entrenamiento y 59 de evaluación independiente), abarcando los estados de Puebla, Hidalgo, Tlaxcala y Guanajuato. La base de datos integra cinco fuentes independientes: (i) series temporales multiespectrales de Sentinel-2 (L2A, reflectancia de superficie a $10–20$ m) y PlanetScope (3 m); (ii) reanálisis meteorológico diario a mesoescala de NASA POWER ($0.5°$) y Open-Meteo (5 km); (iii) micro-topografía SRTM (30 m), derivando pendiente, concavidad y el Índice de Posición Topográfica (TPI) a radios de 360 m, 840 m y $1{,}800$ m; (iv) estadísticas agrícolas municipales del SIAP (2018–2024); y (v) contigüidad poligonal exacta obtenida mediante intersecciones vectoriales espaciales. Para asegurar consistencia geométrica, las firmas espectrales se agregaron calculando el

promedio zonal recortado al 10% interno de cada polígono, mitigando el efecto de borde y pixeles mixtos en caminos y linderos.

4.2. Esquemas de Validación y Prevención de Fuga de Información

Para garantizar estricta generalización, se definieron dos regímenes de evaluación exentos de fuga de datos (*target leakage*):

1. **Validación estratificada 70/30 (5 pliegues):** Reproduce el mecanismo de asignación aleatoria intra-estatal revelado en las directrices oficiales, complementado con 30 simulaciones Monte Carlo independientes para estimar la estabilidad de los estimadores.
2. **Validación por bloques espaciales (*Spatial Block CV*):** Tres esquemas de agrupamiento geográfico estricto (principal-5, balanceado-4 y rotado-45-5) que aíslan cuadrantes espaciales enteros para evaluar la capacidad de extrapolación territorial.

Se congeló un protocolo de registro inmutable donde cualquier transformación estadística, imputación o cálculo de referencias se ejecutó exclusivamente sobre el subconjunto de entrenamiento de cada pliegue.

4.3. Ingeniería de Características Fisiológicas y Ventanas Fenológicas

Se formularon siete familias de características dinámicas (F_1–F_7) sincronizadas con la fisiología del cultivo:

- **Alineación fenológica (F_1):** Fecha de vigor máximo (t_{pico}), vigor en espigamiento y tasa de senescencia.
- **Índices biofísicos y estrés (F_2, F_4):** Absorción de radiación (FAPAR), índice de área foliar (LAI), estrés hídrico de dosel (MSI $= B11/B8$) e índices de labranza (NDTI, STI).
- **Piso de daño intraparcelario (F_3):** Cuantiles mínimos locales ($\text{FAPAR}_{\text{min}}$, $\text{SRNDI}_{\text{min}}$) para detectar siniestros parciales enmascarados por la media poligonal.
- **Ciclo completo y agroclima diario (F_5–F_7):** Señal satelital de barbecho invernal (Ene–Mar) y rastrojo post-cosecha (Nov–Dic); además de métricas meteorológicas diarias en ventanas críticas corregidas por gradiente térmico adiabático (-6.5°C/km) y acumulación de aire frío: choque térmico en llenado ($T_{\text{max}} > 31$°C), heladas en antesis ($T_{\text{min}} \leq 0$°C) y déficit de humedad radicular a 7–28 cm.

4.4. Arquitectura de Modelado Bi-Etapa con Desacoplamiento de Régimen

El modelo campeón (E12) se estructura en una arquitectura bi-etapa diseñada para resolver el problema de datos tabulares reducidos y heterogeneidad de reporte:

- **Etapa 1 (Estimador de Régimen y Contigüidad Física):** Desacopla las parcelas por régimen de reporte municipal $r(i) \in \{\text{Comercializadora}, \text{Productor}\}$. La predicción base combina la media de régimen $\mu_{r(i)}$con un kernel de Kriging local ponderado por la distancia euclidiana entre linderos poligonales ($d_{\text{borde}} \leq 35$ m):

$$\hat{Y}_i^{(1)} = \mu_{r(i)} + \sum_{j \in \mathcal{N}(i)} w_{ij} \left(Y_j - \mu_{r(j)}\right),\ w_{ij} \propto \exp\left(-\frac{d_{\text{borde}}(i,j)^2}{2\ell^2}\right)$$

- **Etapa 2 (Corrector Residual Multimodelo):** Modela los residuos $e_i = Y_i - \hat{Y}_i^{(1)}$mediante un ensamble regularizado que combina regresión Ridge con penalización ℓ_2, Procesos Gaussianos (GPR con covarianza Matérn $5/2$) y árboles de gradiente (*CatBoost*) entrenados bajo función de pérdida robusta Huber ($\delta = 0.5$ t/ha):

$$\mathcal{L}_\delta(e_i, \hat{e}_i) = \begin{cases} \frac{1}{2}(e_i - \hat{e}_i)^2 & \text{si } \mid e_i - \hat{e}_i \mid \leq \delta \\ \delta \mid e_i - \hat{e}_i \mid -\frac{1}{2}\delta^2 & \text{en otro caso} \end{cases}$$

- **Encogimiento Adaptativo (*Empirical Bayes Shrinkage* - EAD):** Fusiona la predicción final mediante un factor de contracción $\lambda_i \in [0, 1]$condicionado a la incertidumbre local: $\hat{Y}_i = \lambda_i\left(\hat{Y}_i^{(1)} + \hat{e}_i\right) + (1 - \lambda_i)\mu_{r(i)}$.

4.5. Cuantificación de Incertidumbre mediante Inferencia Conformal

Para dotar al sistema de validez operativa, se calibraron intervalos de predicción al nivel nominal $1 - \alpha = 0.90$utilizando predicción conformal adaptativa (*Split-Conformal* estratificada por región). Para cada estrato k, se calcula el radio no paramétrico $\hat{q}_{k,1-\alpha}$sobre los residuos de validación fuera de pliegue: $\mathcal{C}_{1-\alpha}(x_i) = \left[\hat{Y}_i, -\hat{q}_{k,1-\alpha}\hat{Y}_i + \hat{q}_{k,1-\alpha}\right]$garantizando una cobertura marginal finita demostrable: $P\left(Y_i \in \mathcal{C}_{1-\alpha}(x_i)\right) \geq 1 - \alpha$, sin asumir normalidad en los errores.

5. Resultados y discusión.

5.1. Evolución de Arquitecturas y Desempeño Global

La secuencia experimental demostró una reducción continua del error predictivo al transitar de referencias empíricas a modelos informados por procesos biofísicos. La Tabla 1 resume esta evolución bajo validación estratificada de 5 pliegues y extrapolación territorial.

Tabla 1. Desempeño comparativo en validación estratificada y bloques espaciales.

Modelo / Configuración	**RMSE (**t/ha**)**	**MAE (**t/ha**)**	R^2**Global**	**RMSE Puebla**	**RMSE Hidalgo**	**RMSE Tlaxcala**	**Spatial CV (principal-5)**
B_0(Media Regional)	0.6053	0.4415	0.4906	0.5897	0.7731	0.3747	0.7440
R_{08}(Control Previo)	0.5056	0.3547	0.6446	0.5923	0.3968	0.3890	0.6596
E_{09}(Régimen Fuente)	0.4880	0.3364	0.6690	0.5848	0.3329	0.3847	0.5128
E_{10}(Linderos ≤ 35 m)	0.4852	0.3381	0.6726	0.5796	0.3332	0.3870	0.5109
E_{12}(**Maestro Integral**)	**0.4812**	**0.3399**	**0.6781**	**0.5747**	**0.3330**	**0.3814**	**0.5104**

El ensamble E_{12}consolida una ganancia neta de $+3.35$puntos porcentuales en R^2y una reducción de -0.0244 t/haen RMSE respecto a R_{08}. En una simulación Monte Carlo de 30 sorteos Holdout 70/30, E_{12}exhibió una robustez notable con un $\text{RMSE}_{\text{medio}} = 0.4741$ t/ha y $R^2_{\text{medio}} = 0.6728$.

5.2. Desacoplamiento de Régimen y Contigüidad de Linderos

El avance sustancial ocurrió al corregir dos fuentes estructurales de variabilidad:

1. **Heterogeneidad de Reporte:** Separar municipios con báscula de comercializadora (Almoloya, Cuautepec: precisión a dos decimales, $\sigma \leq 0.19$) de aquellos con encuestas a productores (redondeo a 0.5o 0.1 t/ha) eliminó el sesgo de arrastre regional. Esto redujo el error en Hidalgo de 0.3968a 0.3329 t/ha, capturando el 81.1%de la varianza local ($R^2 = 0.8114$).
2. **Contigüidad Física de Polígonos:** Al comprobar que el 42.4%de los lotes de prueba colindan directamente ($d \leq 25$ m) con lotes de entrenamiento, el kernel de frontera transfirió la autocorrelación edafológica local, bajando el RMSE global a 0.4852 t/ha.

5.3. Impulsores Fisiológicos y Control de Varianza Regional

Cada cuenca productiva respondió a mecanismos agroecológicos dispares:

- **Puebla:** Región de alta dispersión ($Y \in [2.15, 4.60]$ t/ha). La humedad invernal de barbecho en Ene–Mar (g1_pl_ndvi_janmar, $r = +0.335$), la pendiente y el piso mínimo de absorción de radiación (f3_fapar_min_early) explicaron los predios anómalos (AGC_171 y AGC_024), donde lotes planos extensivos sufrieron estrés basal.
- **Hidalgo:** Dominado por el vigor temprano PlanetScope 3 m ($r = +0.796$) y la temperatura mínima diaria en llenado de grano (g2_min_temp_grainfill, $r = -0.493$), donde las heladas nocturnas en fondos de valle frenan el peso específico del grano.
- **Tlaxcala:** Determinada por el piso de daño intraparcelario (f3_damage_floor_early, $r = +0.473$) y caídas por helada en senescencia tardía.

5.4. Robustez Espacial, Cobertura Conformal y Límite de Bayes

Ante extrapolación espacial estricta (principal-5), donde se evalúan regiones geográficas enteras no vistas en el entrenamiento, E_{12}limitó el RMSE a 0.5104 t/ha ($R^2 = 0.6378$, reduciendo -0.1492 t/hafrente a R_{08}). Asimismo, la calibración conformal al 90%nominal demostró una cobertura empírica exacta del 93.48%, reduciendo la amplitud media a 1.558 t/ha (110 kg/ha más estrecha que el control). El error residual restante (MAE ≈ 340 kg/ha) converge hacia el límite teórico de error irreducible, condicionado por variables no captables satelitalmente

como el cultivar genético sembrado (*Esmeralda* vs. *Alina*), la dosis de fertilización nitrogenada y el redondeo de encuesta.

5.5. Interpretación Económica del Error y Limitaciones en Decisiones Reales

Para evaluar la utilidad práctica de la inferencia, el error debe traducirse a la economía del agricultor y delimitarse en la operativa de campo:

- **Impacto Financiero de la Desviación (**t/ha**):** A un precio de mercado de $\$5{,}800$ MXN/ty costos de producción de $\$13{,}500$ MXN/ha, un rendimiento medio de 3.0 t/haarroja un margen neto de $\approx \$3{,}900$ MXN/ha. Un error moderado de ± 0.34 t/ha (MAE) representa una desviación de $\approx \$1{,}970$ MXN/ha; es un rango absorbible que no altera la solvencia ni compromete el pago del crédito. Por el contrario, un error descalibrado de ± 1.0 t/hadistorsiona el balance en $\$5{,}800$ MXN/ha, destruyendo por completo el margen de utilidad neta e induciendo decisiones crediticias erróneas.
- **Limitaciones para la Decisión en Campo:**
    1. *Decisiones binarias de cosecha:* La predicción no debe sustituir la inspección física cuando el intervalo conformal sea amplio (> 1.8 t/ha); descartar un predio sin aforo arriesga abandonar cosechas viables frente al costo de trilla ($\approx \$2{,}500$ MXN/ha).
    2. *Discrepancia entre volumen y calidad maltera:* El modelo predice masa (t/ha), pero el ingreso final depende de castigos de calidad industrial (proteína entre 10.5–12.5%y calibre $> 85\%$), los cuales pueden devaluar el grano a precio forrajero (castigo del 30–40%).
    3. *Siniestros súbitos de pre-cosecha:* El corte satelital previo a la trilla es ciego a granizadas terminales, acame por vientos tardíos o germinación en espiga por lluvias atípicas de noviembre.

6. Uso de la Ciencia de Datos en la Inclusión Financiera del Sector Agro

Históricamente, la agricultura de temporal en el Altiplano Central Mexicano ha permanecido al margen del sistema bancario formal debido a la asimetría de información y a la elevada incertidumbre climática. Los pequeños y medianos productores, desprovistos de garantías inmobiliarias líquidas y con historial crediticio limitado, enfrentan primas de riesgo excesivas o son orillados a mecanismos informales de financiamiento con tasas predatorias. La falta de herramientas objetivas para cuantificar la capacidad de pago y el riesgo agronómico perpetúa una trampa de subcapitalización que restringe la adopción de paquetes tecnológicos mejorados.

La ciencia de datos y la teledetección satelital transforman este paradigma al convertir la biofísica del cultivo en un activo financiero auditable. El modelo predictivo desarrollado aporta valor directo a la inclusión financiera en tres vertientes estratégicas:

1. **Originación Crediticia Basada en Desempeño Productivo:** Al sustituir las garantías prendarias tradicionales por el análisis continuo de la trayectoria de vigor satelital y el potencial edafoclimático de cada lote, las entidades financieras pueden evaluar la solvencia de los agricultores con base en su capacidad real de cosecha, reduciendo los costos de originación y aprobando créditos de avío más justos y oportunos.
2. **Mitigación del Riesgo de Base en Seguros Paramétricos:** El monitoreo parcelario de estrés térmico e hídrico erradica el desajuste entre las indemnizaciones y las pérdidas reales en campo (*basis risk*). Los intervalos de predicción conformal al 90%proporcionan umbrales matemáticos objetivos para activar liquidaciones automáticas ante siniestros, protegiendo la liquidez del productor sin depender de inspecciones periciales lentas y costosas.
3. **Integración en Cadenas de Suministro y Contratos de Compra Anticipada:** Respaldar las estimaciones volumétricas antes de la cosecha empodera a los productores para negociar contratos de agricultura por contrato con la industria cervecera en condiciones de equidad, facilitando anticipos de capital de trabajo para insumos de calidad y blindando su rentabilidad económica.

7. Conclusiones

El presente trabajo consolida el diseño, validación rigurosa y puesta en producción de una arquitectura predictiva de vanguardia para la estimación del rendimiento de cebada maltera (*Hordeum vulgare L.*) a escala de parcela individual en el Altiplano Central Mexicano. A través del modelo campeón integral (E12), se demostró que la integración sinérgica de teledetección multiespectral de alta resolución, agroclimatología diaria a mesoescala y aprendizaje estadístico con regularización espacial permite superar sustancialmente a las referencias regionales históricas y a los modelos basados exclusivamente en índices espectrales promedio.

Los resultados empíricos confirman que el sistema alcanza un RMSEde 0.4812 t/ha, un MAEde 0.3399 t/ha (≈ 340 kg/ha) y un coeficiente de determinación de $R^2 = 0.6781$bajo validación estratificada de 5 pliegues, respaldado por una simulación Monte Carlo de 30 sorteos con un error medio de 0.4741 t/ha. Asimismo, el modelo demostró una notable capacidad de generalización geográfica en escenarios de extrapolación territorial estricta (RMSE $= 0.5104$ t/ha en bloques espaciales ciegos) y una calibración de incertidumbre sólida mediante inferencia conformal adaptativa, logrando una cobertura del 93.48%al nivel nominal del 90%.

El éxito metodológico de esta investigación radica en tres innovaciones determinantes:

1. **Desacoplamiento de regímenes de reporte:** Aislar las mediciones continuas de básculas industriales de las declaraciones de productores sujetas a redondeo eliminó el sesgo de arrastre regional, explicando hasta el 81.1%de la varianza en zonas de alta tecnología como Hidalgo.
2. **Contigüidad de linderos físicos:** La incorporación de un kernel de proximidad borde-a-borde capturó la continuidad edafológica y de manejo entre predios contiguos ($d \leq 35$ m).
3. **Fenología dinámica y agroclima diario:** La sincronización de índices biofísicos con eventos críticos de choque térmico y heladas radiativas permitió diagnosticar con precisión siniestros localizados que antes quedaban ocultos en métricas estacionales globales.

En virtud de la proximidad del modelo al piso de error irreducible ($\approx 200–300$ kg/ha), las líneas futuras de desarrollo no deberán centrarse en una mayor parametrización algorítmica, sino en la captura sistemática de micro-variables de campo: la identificación del cultivar sembrado, la fertilización nitrogenada de fondo y las propiedades físico-químicas del suelo. En su estado actual, la solución desarrollada constituye una herramienta operativa robusta y auditable, lista para transformar la gestión de abasto agroindustrial y democratizar el acceso al crédito y al seguro paramétrico para los agricultores del país.